

Fallas generales de clientes de izzi durante el Mundial 2026

Vega Barrera Efrén

1. Problema, pregunta y decisión

1.1. Planteamiento del problema

Durante el Mundial 2026 circularon reportes en medios digitales sobre dificultades para seguir los partidos a través de ViX. Esa percepción motiva la revisión de los registros de afectaciones de clientes de **izzi Telecom**, el lugar donde trabajé desde septiembre del 2025 hasta septiembre del 2026, para conocer si el periodo del torneo presentó un comportamiento diferente al observado en los dos años anteriores.

En este proyecto analizo **fallas generales de izzi**, que pueden involucrar **Internet, Telefonía o Vídeo**. Los registros permiten estudiar las afectaciones asociadas a incidencias generales y su distribución temporal y territorial.

El problema consiste en contrastar la percepción de deterioro del servicio con evidencia sobre las fallas registradas. Para hacerlo, es necesario distinguir la existencia de afectaciones, su cantidad y su repetición frente al histórico. La pregunta no se resuelve únicamente contando registros del periodo del Mundial.

La relación con ViX es el contexto que origina la investigación. Una falla general de izzi no identifica por sí sola una interrupción de ViX ni demuestra que el cliente estuviera viendo un partido.

1.2. Pregunta principal

¿Se registraron afectaciones por fallas generales para clientes de izzi durante el Mundial 2026 y cómo se comparan su volumen y repetición con las mismas fechas de 2024 y 2025?

La comparación permitirá examinar si los registros de izzi respaldan una percepción de aumento de afectaciones durante ese periodo. El alcance de la respuesta se refiere a las fallas generales registradas; valorar toda la experiencia de uso de ViX requiere información adicional sobre la plataforma y sus usuarios.

Objetivo general: comparar las afectaciones registradas por izzi durante el Mundial 2026 con las de 2024 y 2025, para evaluar el comportamiento histórico de las fallas de sus

clientes.

Objetivos específicos:

- Comparar clientes afectados, incidencias generales, dispositivos identificados y combinaciones cliente–incidencia.
- Examinar la repetición de fallas por cliente afectado.
- Ubicar diferencias por entidad federativa, hub y plaza, además de la comparación nacional.
- Observar el comportamiento del periodo completo, de cada día y de las ventanas asociadas a los partidos.

1.3. Hipótesis de trabajo

El periodo del Mundial 2026 podría presentar más afectaciones o mayor repetición de fallas que las mismas fechas de 2024 y 2025.

También se contempla que los registros muestren un comportamiento similar o menor, o diferencias que dependan del territorio y del intervalo observado. Evalúo estas posibilidades en las secciones 7 y 11 y tomo mi decisión en las secciones 12 y 15. Respaldo el aumento descriptivo registrado y mantengo separada la causalidad, que mis fuentes no permiten identificar.

1.4. Decisión que se busca sustentar

La decisión es **determinar si el diagnóstico de un aumento de fallas generales para clientes de izzi durante el Mundial está respaldado por sus registros históricos**, antes de adoptar esa interpretación a partir de los reportes en medios digitales.

La lectura de los datos deberá permitir distinguir entre evidencia de aumento, un comportamiento similar o menor y evidencia insuficiente para responder en algún intervalo. Si aparecen diferencias, la interpretación debe conservar su ubicación temporal y territorial.

El juicio de que el servicio fue «tan malo como se decía» se concreta aquí en aspectos observables: **cantidad de clientes afectados, cantidad de incidencias y repetición de fallas**. Estos aspectos no equivalen a medir satisfacción, duración de las interrupciones o calidad de reproducción de ViX.

Un incremento frente a 2024 y 2025 tampoco demuestra que el Mundial haya causado las fallas. Del mismo modo, no observar un incremento agregado no descarta afectaciones particulares ni desmiente las experiencias individuales reportadas.

1.5. Referencia temporal del problema

La configuración del proyecto establece:

Elemento	Referencia
Periodo objetivo	Del 11 de junio al 19 de julio de 2026 , ambos incluidos.
Referencias históricas	Del 11 de junio al 19 de julio de 2024 y de 2025 .
Comparación por partido	El mismo mes, día y hora local del inicio de cada partido, trasladados a 2024 y 2025.
Ventana de partido	Desde 30 minutos antes hasta 180 minutos después del inicio; el extremo final se excluye.
Referencia horaria	America/Mexico_City , como utiliza el programa.

Se comparan las mismas fechas y horas locales; el programa no cambia las referencias para hacer coincidir el día de la semana. Las ventanas históricas son intervalos equivalentes de comparación, sin implicar que en 2024 y 2025 no se celebrara un mundial.

La comparación del periodo completo y las comparaciones por ventanas responden a preguntas distintas. Un cliente puede aparecer en varios días o ventanas, por lo que sus conteos no se suman para obtener el total de clientes distintos del periodo.

2. Contexto del negocio y variables relevantes

2.1. izzi, sus servicios y la relación con ViX

Para mi análisis utilizo datos de **izzi Telecom**, cuya fuente es **Servassure NXT**. La información se envía al **Warehouse de izzi, alojado en Snowflake**, donde se transforma mediante **dbt**. izzi ofrece Internet, Telefonía y Vídeo; sus registros de fallas generales me permiten relacionar incidencias con clientes afectados y con el catálogo territorial.

izzi forma parte del negocio de telecomunicaciones de Grupo Televisa. ViX es una plataforma de **TelevisaUnivision**, empresa de la que Grupo Televisa se identifica como su mayor accionista. Esta relación corporativa ayuda a explicar el vínculo comercial entre los servicios de izzi y ViX. [Grupo Televisa: Televisa en breve](#).

En su oferta del Mundial 2026, izzi distingue entre **ViX Premium**, incluido en determinados paquetes, y el complemento **ViX Premium Mundial**, necesario para acceder a los 104 partidos. La oferta comercial no permite identificar qué clientes del extracto contrataron, activaron o utilizaron ese complemento. [izzi: información oficial del Mundial 2026](#).

El proyecto examina las fallas generales de los servicios de izzi. La vinculación comercial con ViX aporta contexto, pero no convierte esos registros en una medición directa de la disponibilidad de la plataforma.

2.2. Reportes públicos sobre ViX durante el Mundial 2026

TelevisaUnivision anunció en enero de 2026 el acceso a los **104 partidos** a través de su oferta Pase Mundial 2026 en ViX. Esto situó a la plataforma como una opción para seguir el torneo completo en México. [TelevisaUnivision: comunicado del 15 de enero de 2026](#).

El 18 de junio, **La Jornada** informó de reportes de interrupciones durante el encuentro Colombia–Uzbekistán y de la solicitud de Profeco de un informe sobre las incidencias. La nota también recogió la explicación de ViX, que atribuyó ese episodio a un problema en la distribución de la señal mediante Prime Video. [La Jornada: reportes de fallas y respuesta de ViX, 18 de junio de 2026](#).

Estos antecedentes documentan el motivo de la investigación. Los reportes periodísticos y las explicaciones de las empresas corresponden a fuentes externas: no están enlazados con las incidencias ni con los clientes del conjunto de datos de izzi.

La comparación histórica se utilizará para evaluar el comportamiento de las afectaciones generales de izzi en ese contexto, sin atribuir una causa a partir de la coincidencia de fechas.



2.3. Qué representa una afectación en este proyecto

Una **incidencia general** se identifica mediante `WIDMT_INCIDENCIA_REMEDY`. Los registros de clientes permiten conocer qué identificadores de cliente están asociados a esa incidencia.

En mi análisis defino una **falla por cliente** como una combinación distinta de cliente e incidencia general. Una misma incidencia puede afectar a varios clientes y un mismo cliente puede estar asociado a varias incidencias.

En la operación de izzi, **solo un cliente activo puede presentar una falla general**. Por ello, interpreto la presencia de una afectación elegible como correspondiente a un cliente activo

al momento de esa falla. Esta condición de negocio es distinta de la existencia de un registro en el CRM y no se deduce de `flg_eliminado = 0`.

Servicio comprendido en los datos	Contexto para interpretar el problema
Internet	Es el servicio de conectividad. Una afectación de Internet y un error de una plataforma de streaming son eventos distintos que requieren identificación propia.
Telefonía	Corresponde al servicio de voz de izzi. Sus afectaciones forman parte del alcance general, sin demostrar una interrupción de la transmisión de un partido.
Vídeo	Corresponde al servicio de televisión/vídeo de izzi. Su inclusión en las fallas generales no permite equiparar cada registro con una falla de ViX.

En mi análisis agrego las fallas generales y no las desgloso por estos tres servicios.

Internet, Telefonía y Vídeo describen el alcance empresarial que considero; no los utilizo como una variable de clasificación en el programa ya que no pude conseguir esa data.

Esta distinción evita interpretar una afectación del conjunto como si necesariamente fuera una falla de Internet, de Vídeo o de ViX.

2.4. Variables de origen y su contexto

Las siguientes variables son utilizadas por el programa para relacionar registros, ubicar afectaciones y efectuar conteos. Los identificadores funcionan como llaves de análisis; no representan cantidades ni niveles de gravedad.

Variable	Significado en el proyecto	Uso y contexto
<code>WIDMT_INCIDENCIA_REMEDY_CLIENTE</code>	Identificador del registro de afectación de cliente.	Distingue registros de la fuente de clientes; por sí solo no equivale al conteo de fallas cliente–incidencia.
<code>WIDMT_INCIDENCIA_REMEDY</code>	Identificador de la incidencia general.	Enlaza la afectación del cliente con la fuente de fallas generales y permite contar incidencias distintas.
<code>WIDMT_CLIENTE</code>	Identificador del cliente.	Permite contar clientes afectados distintos y estudiar la repetición de incidencias por cliente.
<code>WIDDIM_REGION</code>	Identificador de la dimensión territorial.	Enlaza el registro de afectación con las etiquetas geográficas del catálogo.

Variable	Significado en el proyecto	Uso y contexto
MAC	Identificador MAC del dispositivo informado en la afectación.	Permite contar dispositivos identificados distintos. Puede faltar; no equivale a un cliente ni identifica el uso de ViX.
FECHA_INCIDENCIA	Fecha y hora del registro de afectación al cliente.	Determina su ubicación temporal. El programa la interpreta en UTC y la convierte a America/Mexico_City .
FECHA_ENVIO	Fecha y hora registrada en la fuente de incidencias generales.	El programa la interpreta como hora de México y la utiliza para conciliar las fechas de ambas fuentes.

Los conteos del análisis consideran las afectaciones enlazadas con una incidencia general. Un registro de cliente sin ese enlace no se incorpora a las comparaciones.

Variables territoriales y del calendario

Variable	Significado y función
ENTIDAD_FEDERATIVA	Etiqueta estatal del catálogo; es uno de los niveles configurados para comparar afectaciones.
HUB_CM	Agrupación denominada hub en el catálogo de izzi; permite comparar afectaciones en ese nivel.
PLAZA	Etiqueta de plaza del catálogo; permite comparar afectaciones en ese nivel.
REGION y SUBREGION	Campos de la dimensión territorial que se cargan en el programa; no son niveles de salida habilitados en la configuración actual.
PARTIDO_ID	Identificador del partido del calendario; distingue las ventanas asociadas a cada encuentro.
PARTIDO	Nombre o descripción del encuentro; permite identificarlo en las comparaciones.
FECHA_MX	Fecha del partido en la referencia horaria de México usada por el calendario.
HORA_INICIO_MX	Hora de inicio del partido; junto con la fecha define el inicio de la ventana temporal.

El resultado **nacional** es una agregación calculada por el programa, no una entidad adicional del catálogo. Los niveles territoriales son agrupaciones de los registros; no se presupone una ubicación física exacta ni una causa técnica a partir de sus etiquetas.

2.5. Variables derivadas para responder la pregunta

Las variables derivadas resumen los registros dentro de un intervalo y un territorio.
Documento su significado y las utilizo después en mis tablas e interpretaciones.

Variable	Definición	Qué permite observar
CLIENTES_DISTINTOS	Número de identificadores de cliente distintos afectados en el intervalo y territorio.	Alcance de las afectaciones entre los clientes registrados.
INCIDENCIAS_DISTINTAS	Número de incidencias generales distintas asociadas a esos clientes.	Cantidad de eventos generales registrados con afectaciones enlazadas.
MAC_DISTINTAS	Número de MAC distintas informadas.	Alcance entre los dispositivos identificados; no incluye MAC faltantes.
FALLAS_CLIENTE	Número de pares distintos (WIDMT_CLIENTE, WIDMT_INCIDENCIA_REMEDY) .	Afectaciones considerando que un cliente puede sufrir varias incidencias.
FALLAS_PROMEDIO_POR_CLIENTE	$\frac{FALLAS_CLIENTE}{CLIENTES_DISTINTOS}$, cuando el denominador es mayor que cero.	Repetición media de incidencias por cliente afectado ; no es una tasa sobre toda la cartera activa.
PROMEDIO_HISTORICO_<METRICA>	Promedio de los conteos equivalentes de 2024 y 2025 para cada métrica base.	Referencia histórica conjunta, además de las comparaciones por año.
DIF_<METRICA>_VS_<REFERENCIA>	Conteo de 2026 menos el conteo de referencia.	Diferencia absoluta frente a 2024, 2025 o al promedio histórico.

Variable	Definición	Qué permite observar
<code>VAR_<METRICA>_PCT_VS_<REFERENCIA></code>	$100 \times (\text{conteo_2026} - \text{referencia}) / \text{referencia}$	Diferencia relativa; queda vacía cuando la referencia es cero o no está disponible.
<code>COBERTURA_COMPLETA</code>	Indicador de cobertura temporal utilizado por el programa para los intervalos comparados.	Distingue comparaciones con cobertura disponible; no garantiza que todos los eventos reales estén registrados.

Contexto del conteo: un cliente asociado a dos incidencias aporta un cliente distinto y dos fallas cliente–incidencia. Si existen varias MAC para el mismo cliente y la misma incidencia, el par cliente–incidencia se cuenta una sola vez.

El programa también utiliza `CLIENTES_DISTINTOS`, `INCIDENCIAS_DISTINTAS` y `MAC_DISTINTAS` como variables de su evaluador de anomalías. Desarrollo su justificación, cálculo y sensibilidad en la sección 10.

Las variables utilizadas por el programa no identifican el consumo de ViX ni la contratación del pase, y no incorporan la duración de las interrupciones o el total de clientes activos. Por ello, estos conteos no constituyen una medida directa de disponibilidad de ViX ni de la probabilidad de falla de cualquier cliente de izzi. Una ausencia de fallas registradas tampoco demuestra por sí sola que ese cliente tuviera el servicio activo en el año correspondiente.

3. Población o universo

3.1. Universo organizacional y población observada

Para mi proyecto parto de un universo histórico de fallas de clientes de izzi que supera los **168 millones de registros**, con historia **desde febrero de 2021** y **con las reglas de negocio ya aplicadas**. Sobre ese universo apliqué el filtro temporal de este proyecto.

Utilizo las reglas de negocio y de asociación de clientes de los modelos productivos de **dbt para el Warehouse de izzi en Snowflake**. Los SQL de `anexos_sql/` son el resultado de su compilación. El código productivo parametriza las fechas para permitir el reprocesamiento; así aplico **los mismos filtros a la información de 2024, 2025 y 2026**. Documento este funcionamiento con mayor detalle en la sección 4.2.

Para definir la población de mi estudio distingo tres conjuntos:

Conjunto	Delimitación
Universo histórico elegible del Warehouse	Más de 168 millones de registros de fallas de clientes, desde febrero de 2021, después de las reglas de negocio y antes del filtro temporal que apliqué al proyecto . No equivale a clientes ni a incidencias generales distintas.
Extracto temporal disponible	Las 64 partes de afectaciones de clientes que conservan los años 2024, 2025 y 2026, del 10 de junio al 20 de julio, junto con las fuentes de incidencias generales y la dimensión territorial utilizadas para sus cruces.
Población efectivamente analizada	Registros de ese extracto que cumplen los requisitos del programa, se encuentran en los intervalos locales definidos y se enlazan con una incidencia general y el catálogo territorial. Los conteos se deduplican según la unidad correspondiente.

Las reglas de negocio restringen las afectaciones de clientes a **Netcool y EAssure**, identificados mediante `submitter` , y a las asociaciones con clientes y equipos que cumplen los filtros y cruces del SQL anexo. Su detalle se presenta en la sección 4.2.

El universo observado queda condicionado por el registro organizacional, las reglas de asociación, la extracción y el filtro temporal. **En mi estudio describo las afectaciones identificadas en ese conjunto**, sin equipararlas a toda la cartera de clientes, a todos los eventos reales de la red o a los usuarios de ViX.

El filtro Netcool/EAssure se aplica a la construcción de las **afectaciones de clientes**. El SQL anexo de incidencias generales no contiene esa misma restricción de `submitter` ; una incidencia solo participa en las métricas de afectación cuando tiene clientes elegibles enlazados. No documento aquí la fecha de corte del universo histórico ni su conteo exacto, por lo que no calculo una proporción de retención respecto de los más de 168 millones.

3.2. Unidades de observación y de análisis

Una fila física, un cliente y una falla general representan unidades distintas. Su identificación evita interpretar el volumen del extracto como cantidad de clientes o sumar conteos que se superponen.

Unidad	Identificador o definición	Uso en el estudio
Registro de afectación	<code>WIDMT_INCIDENCIA_REMEDY_CLIENTE</code> .	Unidad de entrada de la fuente de clientes. El programa conserva una fila por identificador al cargarla; su cantidad no equivale al número de fallas cliente–incidencia.
Afectación cliente–incidencia	Par distinto (<code>WIDMT_CLIENTE</code> , <code>WIDMT_INCIDENCIA_REMEDY</code>) .	Unidad contada en <code>FALLAS_CLIENTE</code> . Varias filas o MAC del mismo par no crean

Unidad	Identificador o definición	Uso en el estudio
		nuevas afectaciones en esta métrica.
Cliente afectado	<code>WIDMT_CLIENTE</code> distinto dentro del intervalo y agrupación.	Unidad de <code>CLIENTES_DISTINTOS</code> y del análisis de repetición. El archivo por cliente reúne a quienes aparecen con afectaciones enlazadas en al menos uno de los tres periodos.
Incidencia general	<code>WIDMT_INCIDENCIA_REMEDY</code> distinto con afectaciones elegibles enlazadas.	Unidad de <code>INCIDENCIAS_DISTINTAS</code> . Una incidencia puede asociarse a muchos clientes.
Dispositivo identificado	<code>MAC</code> distinta informada en los registros seleccionados.	Unidad de <code>MAC_DISTINTAS</code> ; una MAC no se interpreta como un cliente. Los registros sin MAC pueden contribuir a los otros conteos.
Intervalo–territorio	Combinación de periodo completo, día o ventana de partido, con nivel y etiqueta territorial; en la comparación se mantienen separados los años.	Unidad agregada para comparar los conteos. Las ventanas pueden compartir clientes e incidencias; estas filas no son observaciones independientes de personas o eventos.

Por ejemplo, un cliente asociado a dos incidencias aporta **un cliente distinto y dos pares cliente–incidencia** en el intervalo que las contiene. Si una de esas incidencias aparece con dos MAC, el número de pares no aumenta por ese motivo.

Los clientes sin afectaciones registradas en ninguno de los periodos **no forman una población de control de clientes sin fallas**. Para construirla se necesitaría la cartera activa y su exposición al servicio en cada año. Un cero en un año del archivo por cliente significa ausencia de incidencias enlazadas registradas para ese identificador en ese periodo, con la cobertura disponible; no acredita que el cliente tuviera servicio activo.

3.3. Delimitación temporal y territorial

Dimensión	Alcance de la población analizada
Periodo objetivo	11 de junio a 19 de julio de 2026 , ambos incluidos, en <code>America/Mexico_City</code> .
Periodos históricos	Las mismas fechas de 2024 y 2025 , con sus horas locales equivalentes. No se sustituyen por otros periodos ni se ajustan al mismo día de la semana.

Dimensión	Alcance de la población analizada
Intervalo técnico del periodo completo	Desde el 11 de junio a las 00:00:00 hasta el 20 de julio a las 00:00:00 , con el extremo final excluido, en cada año. El 20 de julio no añade un día al periodo analítico.
Días	Cada día local se considera como un intervalo con inicio incluido y final excluido.
Ventanas de partido	Para los 104 partidos del calendario disponible: desde 30 minutos antes hasta 180 minutos después de su inicio, con final excluido; las ventanas históricas trasladan el mismo mes, día y hora local a cada año.
Territorios	Registros vinculados a <code>Dataset_Dim_Region.csv</code> , agrupados por ENTIDAD_FEDERATIVA, HUB_CM y PLAZA . El resultado nacional agrega el conjunto elegible, no acredita por sí solo cobertura de toda la red nacional.

La configuración operacional se obtiene de `config.json`. El filtro previo de clientes conserva del **10 de junio al 20 de julio** en 2024, 2025 y 2026; ese margen se aplica sobre `FECHA_INCIDENCIA` antes de la conversión horaria realizada por el programa. Los límites definitivos se seleccionan después en hora local. Los días del margen no se usan como controles adicionales.

La población del periodo completo, la de un día y la de una ventana pueden superponerse. Cada conteo de clientes, incidencias, MAC o pares se obtiene dentro de su propio intervalo y agrupación. **No se suman los clientes distintos de días, territorios o partidos para obtener el total nacional del periodo.**

3.4. Inclusiones y exclusiones

El alcance empresarial comprende fallas generales relacionadas con **Internet, Telefonía y Vídeo**, como se documentó en la sección 2.3. El programa las agrega; no aplica una selección analítica de usuarios de ViX ni presenta una clasificación por esos servicios.

Criterio	Efecto sobre la población
Remitentes de las afectaciones	Selecciono Netcool y EAssure por ser fuentes de calidad. Excluyo otros remitentes para reducir el riesgo de incidencias de usuarios no verídicas o duplicadas respecto de las que envían esas fuentes.
Identificación y asociación en el Warehouse	Se requieren las correspondencias entre incidencia, identificador de equipo, dimensión de clientes y cuenta organizacional que establece el SQL. Una falla sin esas correspondencias no llega a su salida.
Filtros de clientes y equipos	Quedan fuera los valores de cliente expresamente excluidos, equipos con <code>orig_id</code> distinto de 3 o con <code>flg_eliminado</code> distinto de 0, y asociaciones que no satisfacen las condiciones de vigencia descritas en 4.2.
Fechas del análisis	Quedan fuera de cada comparación los registros cuya fecha local no pertenece a su intervalo. El extracto con margen no amplía automáticamente la población analítica.

Criterio	Efecto sobre la población
Campos requeridos	El cargador omite registros sin los campos obligatorios de afectación, incidencia, cliente, región o fecha. MAC es opcional ; su ausencia no elimina el registro de los conteos de clientes o incidencias.
Incidencia general enlazada	Las afectaciones sin correspondencia con una incidencia general se excluyen de las métricas y se contabilizan en el control de calidad. Las incidencias generales sin afectaciones elegibles tampoco contribuyen a esas métricas.
Catálogo territorial	Una llave de región sin correspondencia provoca la detención del programa. Una etiqueta territorial vacía de una llave válida se conserva como NO IDENTIFICADA .
Cartera activa y uso de ViX	El estudio no incorpora como población a todos los clientes activos ni identifica espectadores, contratantes o usuarios de ViX.

En mis datos, `orig_id = 3` **identifica el CRM de izzi**; no es una categoría de tecnología. El SQL incluye `tipo_tecnologia` en su salida, pero no utilizo esa variable para desglosar el análisis.

Documento `flg_eliminado = 0` como una condición de existencia del registro en el CRM, **no como un indicador de cliente activo**. En el SQL anexo, el filtro se aplica a `ttc_dim_equipos`, dentro de `dim_equipos_filtro`.

Distingo la existencia del registro en el CRM de la actividad del cliente: **solo un cliente activo puede presentar una falla general**. Los clientes activos sin afectaciones registradas no aparecen por ese motivo en la población analizada, y los registros del CRM no sustituyen a un padrón de cartera activa.

3.5. Qué población permiten describir los resultados

Los resultados permiten caracterizar el volumen y la repetición de **afectaciones registradas, elegibles y enlazadas** durante los intervalos seleccionados. Se refieren al mecanismo de registro y asociación documentado para este proyecto.

Para inferir la probabilidad de falla de cualquier cliente, una tasa sobre la cartera o la cobertura de toda la red harían falta denominadores y evidencia adicional sobre clientes activos, tecnologías, territorios y eventos que no llegan al extracto. Los más de 168 millones de registros históricos, ya sujetos a reglas de negocio, no proporcionan esos denominadores por sí mismos.

Delimito el universo histórico desde febrero de 2021, **después de las reglas de negocio y antes del filtro temporal** que apliqué. `orig_id = 3` identifica el CRM de izzi. No dispongo de un registro verificable del conteo exacto ni de la fecha de corte de todo el universo histórico; no estimo esos datos ni el tamaño de la cartera a partir de los registros de fallas.

4. Selección y representatividad

4.1. Tipo de selección

En mi proyecto utilizo una **selección determinística por reglas de negocio y por fechas**, y analizo todos los archivos del extracto elegible disponible. No selecciono aleatoriamente a los clientes ni defino probabilidades de inclusión.

Las **64 partes** `remedy_fallas_clientes_filtro_1.csv` a `remedy_fallas_clientes_filtro_64.csv` son fragmentos físicos del conjunto de archivos. No constituyen 64 muestras independientes ni 64 estratos de clientes o territorios. El descubridor de fuentes exige que esté presente la numeración completa antes de analizar.

Procesar todo el extracto evita un submuestreo adicional dentro de esos archivos. **La representatividad respecto del universo organizacional depende de cómo se registraron, asociaron y extrajeron las afectaciones**, además de los filtros que delimitaron el estudio; no se demuestra por haber leído todas las partes.

La elección de 2024 y 2025 proporciona referencias para las mismas fechas y horas locales. Son comparaciones históricas, no grupos de clientes asignados al azar ni controles que permitan atribuir causalidad al Mundial.

4.2. Reglas de negocio documentadas en los anexos

Para construir el conjunto de afectaciones de clientes utilizo las reglas productivas de **dbt en el Warehouse de izzi, alojado en Snowflake**, a partir de información procedente de **Servassure NXT**. En el SQL anexo, esa información se relaciona con registros de incidencias y bitácoras de Helix, y con las dimensiones de clientes y equipos.

Selecciono únicamente los `submitters` de Netcool y EAssure porque son fuentes de calidad. Un usuario puede generar una incidencia que no sea verídica o que duplique lo ya reportado por Netcool o EAssure. Esta selección reduce ese riesgo; no presupone que todos los reportes de usuarios sean incorrectos.

En la tabla documento las condiciones de `mt_incidencias_remedy_clientes.sql` y su efecto sobre la población de mi análisis.

Etapas del SQL de clientes	Regla observable	Justificación y efecto para delimitar el estudio
Remitentes	<code>submitter</code> restringido a EAssure y Netcool en las rutas de incidencias y bitácoras.	Priorizo fuentes de calidad y excluyo reportes de otros remitentes por el

Etapa del SQL de clientes	Regla observable	Justificación y efecto para delimitar el estudio
Dimensión de clientes	Excluye <code>widmt_cliente = '632667547E7CD3E0466547863E1207A8C0C0C549'</code> y <code>cliente = '1'</code> ; exige vigencia de la fila SCD en <code>current_date()-1</code> .	riesgo de incidencias no verídicas o duplicadas. Restringe los identificadores y versiones de clientes que pueden asociarse. El significado administrativo de esos valores excluidos no se presume.
Dimensión de equipos	<code>orig_id = 3</code> , <code>flg_eliminado = 0</code> , exclusión del mismo identificador de cliente y vigencia SCD en <code>current_date()-1</code> .	Selecciono registros procedentes del CRM de izzi. <code>flg_eliminado = 0</code> exige la existencia del registro en el CRM; no acredita que el cliente esté activo. La vigencia SCD delimita la versión del registro para la fecha procesada.
Rutas de identificación	Descripciones de Help Desk con <code>CmMacAddress</code> ; bitácoras con <code>*Affected Subscribers*</code> y <code>CmMacAddress</code> ; nota detallada de Netcool con <code>CmMacAddress</code> ; ruta EAssure con <code>Affected</code> y asociación del <code>Alarm ID</code> a <code>cm_to_alarm_issue</code> .	Recupera identificadores por las rutas expresamente implementadas. Registros sin esos patrones o correspondencias no participan en esas rutas.
Interpretación de identificadores	En las tres rutas de texto se extraen 12 caracteres iniciales que satisfacen <code>^[A-Z0-9]{12}.*</code> , descartando líneas vacías e identificadores nulos. La ruta de alarma utiliza <code>cm_mac</code> .	Condiciona la inclusión al formato que el SQL puede interpretar o a la relación de alarma disponible. El patrón de texto no demuestra por sí solo la validez operativa de cada MAC.

Etapas del SQL de clientes	Regla observable	Justificación y efecto para delimitar el estudio
Correspondencia con equipos	Se construyen candidatos desde <code>mac</code> , <code>mac_2</code> , <code>chip_id</code> y <code>no_serie</code> , con <code>upper(trim(mac_match))</code> , y se cruzan con los identificadores recuperados.	Amplía las posibilidades de enlace previstas en el modelo; la elegibilidad sigue dependiendo de que exista coincidencia con el inventario.
Cruces finales y vigencia del evento	<code>INNER JOIN</code> con equipos, clientes y <code>s_org_ext</code> ; la fecha de incidencia debe estar entre el inicio y fin SCD tanto del cliente como del equipo.	Excluye asociaciones sin correspondencia y exige compatibilidad de las vigencias con la fecha del registro.
Combinación de rutas	<code>UNION</code> , <code>DISTINCT</code> y <code>GROUP BY ALL</code> en las etapas correspondientes.	Consolida filas coincidentes según las columnas de cada etapa. No convierte automáticamente su salida en un conteo de clientes ni de pares cliente–incidencia.
Fecha de procesamiento	El SQL compilado muestra <code>current_date()-1</code> para seleccionar información del día vencido; la ruta de bitácoras contempla también altas del worklog en el día procesado.	El código productivo utiliza variables de fecha para permitir el reprocesamiento de los mismos modelos. Estas fechas operacionales son distintas del periodo fijo que configuro para el análisis.

[mt_incidencias_remedy.sql](#) selecciona incidencias con `incident_number` no nulo y condiciones de alta o modificación relativas a la fecha de ejecución. Convierte `FECHA_ENVIO` a `America/Mexico_City` ; el SQL de clientes conserva el timestamp que el programa interpreta como UTC. El cruce por identificador de incidencia enlaza ambos conjuntos.

izzi trabaja con información del día vencido. Por eso aparece `current_date()-1` en los SQL anexos: son el resultado de una compilación del código productivo de dbt. En los modelos originales, las variables de fecha permiten reprocesar la información de cada día con las mismas reglas de selección y asociación.

Según el funcionamiento organizacional que documento, la parametrización de fechas y el uso de los mismos modelos mantienen los mismos filtros de negocio en 2024, 2025 y 2026. Para mi comparación utilizo esa historia ya transformada y después aplico el filtro temporal del proyecto. Distingo la fecha operacional de procesamiento de las fechas locales del torneo; cambiar la fecha de reproceso no cambia los criterios de elegibilidad.

4.3. Filtros del proyecto y su justificación

Distingo las reglas organizacionales de selección, el extracto temporal publicado y la selección analítica definitiva. Así conservo una frontera precisa entre los antecedentes de preparación y las comprobaciones que puedo reproducir con los archivos actuales.

Etapa	Selección que documento	Función en mi comparación
Extracto temporal publicado	64 partes filtradas de clientes y tres particiones generales, para 2024–2026 y el margen del 10 de junio al 20 de julio.	Recibo las entradas filtradas distribuidas mediante las carpetas configuradas en Drive.
Selección local definitiva	Convierto <code>FECHA_INCIDENCIA</code> desde UTC a México y aplico los límites de <code>periodos_analisis</code> y <code>limites_carga</code> .	Selecciono los intervalos locales con inicio incluido y final excluido.
Requisitos de uso	Exijo afectación, cliente, incidencia, región y fecha; admito MAC ausente y exijo cruces con las fuentes general y territorial.	Conservo observaciones que puedo ubicar y contar según las unidades del estudio.
Deduplicación	Cargo una fila por identificador de afectación y cuento clientes, incidencias, MAC y pares distintos dentro de cada intervalo.	Evito inflar las métricas por archivos fragmentados o varios dispositivos del mismo par.

Documento el margen del prefiltro como un antecedente de la preparación. Para reproducir el estudio empleo los CSV filtrados actuales y el [código analítico](#); no necesito los archivos que se utilizaron para preparar la historia completa. No convierto una fecha ilegible excluida previamente en evidencia de ausencia de falla.

Conservo el periodo completo para observar también las afectaciones fuera de las ventanas de partido. En la sección 10 explico el alcance de la ventana configurada y su falta de calibración con demanda y severidad.

4.4. Evaluación de representatividad y posibles sesgos

La selección permite comparar el comportamiento de los **registros elegibles disponibles**. Los siguientes mecanismos pueden afectar una interpretación más amplia; se identifican como riesgos de selección o comparabilidad, sin afirmar que su magnitud haya sido demostrada.

Mecanismo	Posible efecto en la interpretación	Evidencia necesaria para evaluarlo
Cobertura de remitentes y rutas de identificación	Priorizo Netcool/EAssure por calidad y excluyo otros remitentes; también quedan fuera los registros sin los patrones y enlaces requeridos. Mis resultados describen ese conjunto elegible.	Conteos de registros excluidos por remitente y de descartes en cada ruta y etapa, con fechas equivalentes, para cuantificar el efecto de la selección.
Cruces con clientes y equipos	Asociaciones no encontradas, estados no admitidos o vigencias incompatibles no llegan a la salida del modelo.	Cuantificación de registros sin correspondencia, excluidos por estado y excluidos por vigencia.
Reproceso y vigencia histórica	Los modelos de dbt parametrizan las fechas y aplican los mismos filtros al reprocesar. Las asociaciones deben satisfacer además las condiciones SCD documentadas para la fecha del registro.	Parámetros de fecha y trazabilidad de las cargas, junto con las versiones SCD utilizadas, para reproducir la construcción de los extractos históricos.
Cobertura del mecanismo de registro	Utilizo los mismos filtros de negocio y asociación en los tres años. Aun con filtros iguales, la disponibilidad de información o la cobertura de los sistemas podría afectar la cantidad de registros observables.	Evidencia de cobertura y disponibilidad de las fuentes para valorar posibles diferencias en la captura, sin atribuir las a cambios de filtros.
Tamaño y composición de la cartera	Más afectaciones registradas pueden acompañar cambios en el número de clientes, equipos, servicios o territorios cubiertos. Los conteos no son tasas sobre exposición.	Cartera activa y equipos expuestos por periodo, servicio y territorio, junto con correspondencias comparables entre años.
Fechas equivalentes	El mismo mes y día pueden corresponder a distintos días de la semana y condiciones operativas. Dos años no controlan esas diferencias ni otros acontecimientos concurrentes.	Información contextual para valorar su efecto. La comparación del proyecto conserva las mismas fechas y horas locales.
Clasificación territorial	Cambios en etiquetas o asignaciones de clientes podrían alterar la composición de las agrupaciones.	Catálogos históricos y validación de equivalencias territoriales.
MAC y superposición de unidades	Una MAC faltante afecta al conteo de dispositivos; varios dispositivos por cliente y ventanas solapadas impiden interpretar las filas agregadas como personas o eventos independientes.	Perfil de MAC faltantes y revisión de solapamientos. El programa deduplica cada unidad dentro de cada intervalo.

Estos límites impiden extrapolar automáticamente los conteos a toda la red, a la experiencia de cualquier cliente o a la disponibilidad de ViX. Tampoco permiten afirmar que el Mundial causó las diferencias observadas.

4.5. Qué comprueba la cobertura disponible

Para documentar la cobertura utilizo el archivo existente [control_calidad.json](#). El reporte enumera las 64 partes de clientes y las tres particiones anuales de incidencias generales. En esta sección presento sus comprobaciones:

Comprobación del reporte disponible	Resultado documentado	Alcance
Filas de clientes leídas	25.978.115.	Filas físicas del extracto filtrado leído por esa ejecución; no clientes ni incidencias distintas.
Filas de clientes aceptadas en los límites de carga	24.674.207.	Contador de filas aceptadas antes de la deduplicación por identificador en SQLite; no tamaño final de la población deduplicada.
Filas de clientes omitidas por campos obligatorios incompletos	0.	Describe lo que recibió ese cargador; no descarta omisiones previas en el Warehouse o en el filtro de fechas.
Días sin registros de clientes, de incidencias generales o de su cruce	Ninguno en el periodo del 11 de junio al 19 de julio, para los tres años.	Acredita presencia diaria de registros, no totalidad de eventos ni estabilidad del mecanismo de registro.
Filas sin región en el catálogo e incidencias/filas de clientes sin incidencia general	0 en los indicadores correspondientes.	Acredita correspondencia en el conjunto cargado, no cobertura de registros que nunca llegaron al extracto.

El mismo reporte advierte que la **presencia diaria no garantiza un extracto completo**. Una ejecución futura con un día sin registros requerirá distinguir entre ausencia de eventos y ausencia de datos; no procede interpretar automáticamente esa falta como cero fallas.

No calculo un porcentaje de representatividad dividiendo las filas leídas entre los más de 168 millones de registros históricos, ya sujetos a reglas de negocio. En esta documentación utilizo una cota inferior de ese universo; mantengo pendientes su conteo exacto, fecha de corte y conciliación con el extracto. Incluso una proporción de registros retenidos correctamente calculada describiría retención tras el filtro temporal, no demostraría por sí sola representatividad de toda la red.

4.6. Alcance de la conclusión y documentación de origen

Analizo el extracto bajo reglas explícitas y compruebo su cobertura temporal y sus cruces. Documento como origen organizacional Servassure NXT, el Warehouse de izzi en Snowflake y las transformaciones de dbt. Los dos SQL anexos respaldan las reglas de selección y asociación que explico en 4.2.

Distingo `orig_id = 3` , que identifica el CRM de izzi, de `flg_eliminado = 0` , que expresa existencia del registro de equipo. La regla operativa que documento establece que sólo un cliente activo puede presentar una falla general; esa condición no proporciona un padrón de todos los clientes activos ni su exposición anual.

La reproducción técnica del extracto organizacional completo requeriría registros de extracción y corte, parámetros de las cargas y catálogos históricos. No dispongo de esa evidencia en los archivos vigentes, por lo que no presento las comprobaciones locales como una auditoría integral del Warehouse. Esta limitación delimita el estudio terminado; no deja incompleta su comparación descriptiva.

Mis referencias ejecutables son los [SQL de clientes](#) y [generales](#), la [configuración](#), la [descarga](#), el [análisis](#) y el [control de calidad](#). Para extender mis conteos a tasas o a toda la red necesitaría cartera activa y cobertura comparable por servicio, tecnología y territorio.

5. Fuentes y extracción/ETL

5.1. Cadena de procedencia de los datos

Documento Servassure NXT como fuente organizacional, el Warehouse de izzi en Snowflake como almacenamiento y dbt como transformación de las incidencias y sus afectaciones de clientes. Los SQL compilados de `anexos_sql/` permiten examinar los filtros y cruces de esos modelos.

Etapas	Transformación o traslado que documento	Evidencia vigente
Registro y Warehouse	Relaciono incidencias y bitácoras de Helix con clientes y equipos.	Tablas y condiciones de los dos SQL anexos.
Modelos dbt	Construyo incidencias generales y asociaciones elegibles con los filtros de 4.2.	Consultas compiladas de <code>anexos_sql/</code> .
Extracción y prefiltro	Documento la exportación y la selección temporal del extracto antes de este análisis.	Antecedente organizacional de 5.5 y CSV filtrados publicados.
Partición y publicación	Distribuyo 64 partes de clientes, tres particiones generales y dos referencias.	69 CSV bajo <code>raw_data/</code> , con rutas configuradas.
Descarga y validación	Reutilizo archivos locales válidos o preparo faltantes.	<code>src/descarga.py</code> y <code>scripts/descargar_datos.py</code> .

Etapa	Transformación o traslado que documento	Evidencia vigente
Preparación analítica	Cargo, convierto horarios, relaciono y deduplico desde <code>main.py</code> .	<code>src/analisis.py</code> , el índice derivado y el control de calidad.
Exploración y revisión	Recalculo tablas, figuras, clasificaciones, recurrencia y sensibilidad.	Celdas de este notebook y auxiliares en <code>proyecto/recursos_2/</code> .

Los nombres, encabezados y volúmenes relacionan técnicamente las entradas y salidas. Mantengo separado el origen declarado de los registros de exportación que no están disponibles; no atribuyo a una huella local la autenticación de toda la cadena organizacional.

5.2. Inventario de fuentes y correspondencia con el análisis

La configuración vigente establece `modo_fuentes = "filtrado"` , `carpeta_datos = "raw_data"` , `partes_irc_esperadas = 64` y los años 2024, 2025 y 2026. El programa descubre y procesa estas entradas:

Fuente	Archivo y ubicación relativa a la raíz
Afectaciones de clientes	<code>raw_data/fallas_clientes/remedy_fallas_clientes_filtro_1.csv</code> a <code>_64.csv</code> .
Incidencias generales	<code>raw_data/fallas_generales/Dataset_Fallas_Generales_Historia_2024.csv</code> , <code>_2025.csv</code> y <code>_2026.csv</code> .
Dimensión territorial	<code>raw_data/region_y_calendario/Dataset_Dim_Region.csv</code> .
Calendario	<code>raw_data/region_y_calendario/calendario_partidos_2026.csv</code> .

Los CSV publicados en Drive que utilizo proceden de los modelos dbt de los SQL anexos y de las rutas de filtrado que documento. Obtuve `Dataset_Dim_Region.csv` del Warehouse de izzi y elaboré el calendario con información pública de la FIFA. En 5.6 preciso qué compruebo del calendario local y cuál es su referencia oficial.

Las carpetas de distribución configuradas son:

- [Región y calendario](#): dos CSV.
- [Incidencias generales](#): tres CSV.
- [Afectaciones de clientes](#): 64 CSV.

Estas URLs identifican el medio de distribución. El origen organizacional se documenta por separado. En esta revisión se comprobaron los archivos locales; no se volvió a consultar ni descargar su contenido de Drive.

Utilizo las rutas vigentes de `raw_data/` y de `config.json`. Mi ejecución no requiere directorios ni copias de preparación anteriores.

5.3. Extracción organizacional y filtros previos

Examino las transformaciones de dbt mediante los SQL anexos. El modelo general selecciona incidencias con identificador y condiciones de alta o modificación y convierte `FECHA_ENVIO` a hora de México. El modelo de clientes restringe remitentes a Netcool/EAssure y exige asociaciones con equipos y clientes, con las condiciones de vigencia explicadas en 4.2.

Distingo **fecha de procesamiento, fecha de extracción y periodo analítico**. Las fechas relativas de los SQL compilados documentan el proceso de día vencido; no identifican por sí mismas la ejecución que produjo cada CSV histórico.

El antecedente de preparación conserva el margen del 10 de junio al 20 de julio de los tres años. Utilizo su salida filtrada y cuantifico lo que efectivamente recibió el cargador:

Fuente procesada	Filas leídas	Filas aceptadas en la carga	Filas fuera de sus límites
Cientes	25.978.115	24.674.207	1.303.908
Incidencias generales	561.008	546.343	14.665

Estos contadores proceden del [control de calidad](#). Las cifras se refieren a filas, no a clientes ni incidencias distintas enlazadas. No reconstruyo volúmenes anteriores al prefiltro a partir de documentos que no están en la distribución actual. Tampoco puedo separar las fechas ilegibles excluidas previamente de las fechas válidas fuera del rango.

Las 64 partes son fragmentos físicos del extracto completo disponible. Las tres particiones generales representan los años de comparación; no son muestras aleatorias ni añaden tres referencias por ventana.

5.4. Descarga, validación y carga reproducible

Utilizo `src/descarga.py` para validar los nombres y encabezados de 64 partes de clientes, tres particiones generales y dos referencias. Reutilizo los CSV locales válidos; si faltan archivos, preparo las carpetas configuradas con acceso anónimo, reanudación y reintentos. No inicio el análisis con partes pendientes.

El cargador vuelve a comprobar la numeración, los años, las columnas y el calendario. Procesa lotes de 10.000 filas y crea el índice SQLite derivado. `main.py` localiza su configuración desde la raíz, independientemente del directorio desde el que lo invoque.

Para preparar datos sin analizar, desde la raíz ejecuto:

```
& "$env:TEMP\mundial_mineria_venv\Scripts\python.exe"
scripts/descargar_datos.py
```

Para reconstruir los resultados ejecuto `main.py` con ese intérprete. Después abro este notebook y ejecuto sus celdas. Para comprobar el código puedo utilizar:

```
& "$env:TEMP\mundial_mineria_venv\Scripts\python.exe" -m unittest discover
-s pruebas -v
```

Las pruebas sintéticas verifican el funcionamiento del código; no autentican el origen organizacional ni calibran el detector. Consulto la [guía vigente](#) y el [único archivo de dependencias](#), que incluye descarga, zonas horarias, figuras, kernel y ejecución de notebooks. No necesito pandas ni scikit-learn para leer las salidas y reproducir este estudio.

El coste principal del flujo completo proviene de la descarga, la carga SQLite y los conteos distintos. Las celdas de este documento reutilizan los agregados; leen en flujo el CSV por cliente para recalcular la recurrencia. No atribuyo tiempos de ejecución que no haya medido en el equipo utilizado.

5.5. Fechas y límites de trazabilidad

Documento mi extracción organizacional a principios de septiembre de 2026, antes del día 10, con la precisión disponible. Distingo esa fecha aproximada de las fechas de descarga, ejecución analítica y elaboración del documento.

Referencia temporal	Qué documento	Límite de su evidencia
Extracción del Warehouse	Principios de septiembre, antes del 10.	No dispongo del día y hora exactos, corte por exportación o identificador de carga.
Procesamiento dbt	Día vencido y reproceso mediante fechas parametrizadas.	<code>current_date()-1</code> en una consulta compilada no fecha un CSV.

Referencia temporal	Qué documento	Límite de su evidencia
Entradas analíticas	Archivos filtrados en <code>raw_data/</code> y archivos enumerados en el control.	Sus nombres no certifican identidad con una exportación histórica completa.
Ejecución utilizada	Configuración, resumen y salidas agregadas que leo en las celdas.	La fecha de modificación es una referencia del archivo local; no equivale a la fecha de extracción.
Reproducción del notebook	Fecha de ejecución y tamaños y SHA-256 de las fuentes comunes.	Identifico el contenido local utilizado; no autentico el origen empresarial.

Genero las huellas vigentes al ejecutar el EDA y la revisión. Consulto [manifiesto_edajson](#) y [manifiesto_fuentesjson](#), que incluyen las rutas existentes y sus tamaños. Evito incorporar huellas copiadas de archivos ausentes o de código que haya cambiado.

Para ampliar la trazabilidad organizacional necesitaría los registros exactos de exportación, cortes, parámetros y correspondencias con los CSV publicados. Explicito esa frontera sin inventar fechas o evidencias de extracción.

5.6. Validación del calendario y referencia oficial en CDMX

Utilizo el [calendario local](#) para definir las ventanas. El programa comprueba que contiene 104 identificadores únicos, fechas y horas convertibles y partidos dentro del periodo configurado. Al cargar las salidas compruebo también el número de partidos y la coherencia de sus intervalos.

Mi referencia pública es el [calendario oficial de FIFA](#). Sus horarios programados se presentan en Eastern Time. Para expresarlos en CDMX empleo las zonas IANA `America/New_York` y `America/Mexico_City`; en junio y julio de 2026 sus desplazamientos son UTC-04:00 y UTC-06:00, respectivamente. En una hora ET a medianoche debo considerar el cambio de fecha del instante, además de la diferencia de dos horas.

Distingo mi comprobación técnica del calendario local de una auditoría externa completa por partido. No incluyo una afirmación nueva de 104 coincidencias externas sin conservar un registro reproducible de ese contraste. Mis ventanas representan horarios programados, no tiempos reales de inicio o final ni exposición de los clientes a ViX. El estudio permanece reproducible con el calendario local y las mismas horas de referencia.

6. Preparación y limpieza

6.1. Reglas de lectura y campos requeridos

La limpieza tiene etapas con efectos diferentes: elegibilidad organizacional en dbt, selección temporal del extracto publicado y preparación de los CSV filtrados en el programa. Las reglas de dbt ya se desarrollaron en 4.2; aquí consolido las reglas que determinan la utilización analítica del extracto.

| Regla vigente | Tratamiento implementado | Justificación y alcance | |---|---|---| | Lectura del CSV | Codificación `utf-8-sig` ; normalización de nombres de columnas con `strip().upper()` ; reconocimiento de `,` `|` `;` o tabulador. La dimensión se lee con `|` . | Reconoce las columnas sin depender de mayúsculas, espacios del encabezado o BOM; el separador se adapta al archivo. | | Estructura | Falta de columnas requeridas, encabezados repetidos o archivo vacío producen error. | Evita continuar con una estructura que no permite identificar o relacionar los registros. | | Campos de clientes | Son obligatorios afectación, incidencia, cliente, región y fecha. Una fila con alguno vacío se omite y suma a `filas_incompletas_omitidas` . | Son necesarios para ubicar la fila y calcular sus unidades. La omisión se registra como una exclusión de datos. | | MAC de clientes | La columna debe existir, pero el valor puede faltar. El valor vacío se almacena como `NULL` ; no se imputa ni se elimina por ese motivo al cliente. | Permite conservar clientes, incidencias y pares aunque no se identifique el dispositivo. `COUNT(DISTINCT mac)` excluye los `NULL` . | | Incidencias generales | Identificador vacío: se omite la fila. La fecha debe corresponder al año del archivo y comenzar con el formato esperado `AAAA-MM-DD` . | Permite un enlace con identificador y una partición temporal coherente. Estas comprobaciones no son una validación exhaustiva de todas las fechas de origen. | | Dimensión | Llaves de región vacías o repetidas producen error; etiquetas vacías se sustituyen por `NO IDENTIFICADA` . | Exige una correspondencia unívoca de llave y conserva una categoría explícita cuando falta la etiqueta. | | Calendario | Identificador vacío o repetido, fechas u horas no convertibles, partidos fuera del periodo o cantidad distinta de 104 producen error. | Evita ventanas repetidas o incompletas respecto del calendario configurado. No reemplaza la validación con su fuente. |

El cargador normaliza **los encabezados**, pero no aplica una normalización general de los valores de identificadores o MAC. No elimina separadores de una MAC, no convierte sistemáticamente sus valores a mayúsculas ni interpreta automáticamente textos como `NULL` , `NA` o `N/A` como faltantes. En 6.5 documento el perfil observado para esos casos; no atribuyo al código una limpieza que no realiza.

6.2. Fechas, zonas horarias e intervalos

`FECHA_INCIDENCIA` procede del timestamp que el programa interpreta en **UTC**. `fecha_irc_local` utiliza `datetime.fromisoformat` ; si el valor no contiene zona, le asigna UTC, y si contiene un desplazamiento, lo convierte primero a UTC. Después transforma el instante a `America/Mexico_City` y lo guarda en hora local con precisión de segundos.

`FECHA_ENVIO` ya está en hora de México conforme al SQL de incidencias generales. El programa no vuelve a aplicarle la conversión UTC de clientes. Esta diferencia evita comparar

una fecha UTC con una hora local como si fueran la misma referencia.

Etapa temporal	Tratamiento	Motivo
Filtro previo	10 de junio a 20 de julio de los tres años, sobre la columna de cada fuente; las fechas ilegibles no cumplen la máscara.	Reduce el extracto y conserva margen para la selección local posterior.
Prefiltro de clientes en el cargador	Comparación conservadora del prefijo de fecha UTC, ampliado dos días alrededor de los límites de carga.	Evita convertir fechas que están lejos de los intervalos. El margen técnico no se incorpora al periodo analítico.
Selección definitiva de clientes	Después de convertir a México, aplica <code>inicio <= fecha_mx < fin</code> .	Ubica la afectación dentro de su intervalo local sin incluir dos veces un extremo compartido.
Selección de incidencias generales	Prefiltro por fecha local, con las fechas de ambos extremos incluidas.	Conserva incidencias para los cruces; puede retener el día del extremo final sin ampliar las afectaciones contadas.
Periodo y días	Periodo del 11 de junio a las 00:00 hasta el 20 de julio a las 00:00, fin excluido; cada día se construye con la misma convención.	El periodo analítico comprende del 11 de junio al 19 de julio.
Partidos	Inicio del partido menos 30 minutos; final más 180 minutos, excluido. Misma fecha y hora local en 2024 y 2025.	Conserva la comparación definida, sin sustituirla por otra fecha o día de la semana.

Con el calendario y la configuración revisados, `limites_carga` produce exactamente los intervalos **11 de junio 00:00 a 20 de julio 00:00, fin excluido**, de cada año. En una configuración distinta, la envolvente de carga podría extenderse para incluir ventanas; los intervalos finales seguirían seleccionándose por separado.

Una fecha de clientes que falla en la conversión después de pasar el prefiltro provoca un error con el archivo correspondiente. Las filas que no pasan el prefiltro se contabilizan como fuera de los límites; no se afirma que se haya validado su fecha completa. El filtro previo declarado convierte las fechas ilegibles a `NaT` y las excluye; distingo ese tratamiento del error que produce el cargador definitivo.

La conciliación horaria del control de calidad compara hasta **500 incidencias** enlazadas; el reporte disponible registró **0 diferencias superiores a un minuto** en las 500. El código detiene la ejecución si más del 1 % de las comparaciones difiere en más de 60 segundos. No es una muestra aleatoria ni una auditoría de todas las fechas: para cada incidencia se toma una afectación sin un criterio explícito de prioridad temporal.

6.3. Deduplicación y atributos contradictorios

El programa distingue deduplicar filas al cargar de contar unidades distintas al analizar:

Unidad o tabla	Regla actual	Si dos filas con la misma llave tienen atributos diferentes
Afectación de cliente, tabla afectados	Llave primaria WIDMT_INCIDENCIA_REMEDY_CLIENTE ; INSERT OR IGNORE .	Se conserva la primera fila aceptada . Las siguientes se ignoran aunque cambien cliente, incidencia, región, MAC o fecha local. No se combinan atributos ni se elige automáticamente la fecha más reciente.
Incidencia general, tabla incidencias	Llave primaria WIDMT_INCIDENCIA_REMEDY ; INSERT OR REPLACE .	Se conserva la última fila aceptada para ese identificador, incluida su FECHA_ENVIO . Es la última en orden de lectura, no necesariamente la de fecha cronológicamente mayor.
Dimensión y calendario	Llaves vacías o repetidas se rechazan.	El programa detiene la carga; no selecciona silenciosamente una versión.
Clientes, incidencias y dispositivos	COUNT(DISTINCT ...) dentro de cada intervalo y agrupación.	Se cuentan los valores conservados tras la carga; esta agregación no resuelve un conflicto perdido en la deduplicación anterior.
Fallas por cliente	Par distinto (WIDMT_CLIENTE, WIDMT_INCIDENCIA_REMEDY) .	Varias filas o varias MAC del mismo par contribuyen una sola vez a la falla de ese cliente en el intervalo.

Las partes de clientes se leen en orden numérico del 1 al 64; las particiones generales, por año. Dentro de cada archivo se conserva su orden de filas. Las reglas de primera y última fila proporcionan un comportamiento reproducible para el mismo contenido y orden, pero **no acreditan qué atributo sería correcto si hubiera un conflicto**. Son el comportamiento del código vigente, no una política empresarial de reconciliación confirmada.

En el reporte disponible, las **24.674.207 inserciones aceptadas de clientes** coinciden con la suma de las filas finales de afectados . Las **546.343 inserciones aceptadas de incidencias generales** coinciden con la suma de sus conteos finales. Por diferencia, **la deduplicación por llave no redujo filas aceptadas en ninguna de las dos tablas**. No hay repetición de esas llaves dentro del conjunto aceptado de esta ejecución; esta constatación no abarca los registros descartados antes de la carga ni la historia original.

El índice final no conserva las versiones ignoradas o reemplazadas. En una ejecución que sí presente reducción de filas, ese índice por sí solo no permitiría cuantificar conflictos:

necesitaría conservar o revisar las filas competidoras del extracto filtrado antes de deduplicar y definir el criterio de prioridad que utilizaré. En mi análisis conservo y documento el comportamiento del programa vigente.

6.4. Conciliación de volúmenes y cruces

Concilio las etapas que cuentan con evidencia vigente en el control de calidad. No equiparo filas físicas con clientes, incidencias o pares distintos.

Paso comprobable	Clientes	Incidencias generales
Filas leídas	25.978.115	561.008
Filas fuera de los límites de carga	1.303.908	14.665
Filas omitidas por campos requeridos	0	0 por conciliación de contadores
Filas aceptadas antes de deduplicar	24.674.207	546.343
Filas finales, según conteos diarios	24.674.207	546.343
Reducción por llaves repetidas aceptadas	0	0

El prefiltro general conserva el día del extremo final. Por ello, sus 546.343 filas no son automáticamente las incidencias con clientes del periodo analítico. Para las métricas selecciono la fecha local de cada afectación enlazada.

El reporte contiene 4.830 llaves territoriales y 421.068 incidencias distintas entre las afectaciones cargadas. Registra cero filas sin región, cero incidencias de clientes sin enlace general y cero filas sin ese enlace. La suma de filas diarias con cruce es 24.674.207. Dispongo de registros de clientes, generales y cruce en los 39 días de cada uno de los tres años.

La presencia diaria y la conciliación de los contadores no demuestran que todos los eventos reales estén registrados. Las incidencias generales sin afectaciones elegibles tampoco contribuyen a las métricas de afectación.

6.5. Perfil de MAC y etiquetas territoriales

Trato MAC como un identificador opcional: una afectación sin ese dato puede contribuir a clientes, incidencias y pares, mientras que `COUNT(DISTINCT mac)` excluye los valores almacenados como `NULL`. La carga normaliza encabezados, pero no corrige sistemáticamente formatos o tokens de los valores.

En las tablas agregadas cuantifico MAC distintas y su relación con clientes en la sección 7. No uso la diferencia entre ambos conteos para estimar registros sin MAC: un cliente puede tener varios dispositivos y los denominadores son distintos. La validez operacional de una MAC, la correspondencia única con equipos y el perfil de las filas excluidas requieren comprobaciones adicionales.

Si necesito perfilar las filas cargadas, puedo consultar el índice derivado mediante una conexión SQLite de sólo lectura con `mode=ro` y `PRAGMA query_only=ON` :

```
SELECT substr(fecha_mx, 1, 4) AS anio,
COUNT(*) AS registros,
SUM(mac IS NULL) AS mac_null,
SUM(mac IS NOT NULL AND trim(mac) = '') AS mac_vacia_espacios,
SUM(mac IS NOT NULL AND mac != trim(mac)) AS mac_espacios_borde,
SUM(mac IS NOT NULL AND upper(trim(mac))
      IN ('NULL', 'NONE', 'NAN', 'NA', 'N/A')) AS mac_tokens
FROM afectados
GROUP BY substr(fecha_mx, 1, 4);
```

Esta consulta describe una comprobación adicional y no forma parte de las celdas ejecutadas del documento. No presento sus resultados como mediciones realizadas por esta copia.

Para el territorio, una llave inexistente detiene el análisis; una etiqueta vacía de una llave válida se conserva como `NO IDENTIFICADA` . Distingo esa categoría semántica de la falta de correspondencia de la llave y no imputo una ubicación. Mis resultados se refieren a las agrupaciones conservadas en el catálogo utilizado.

6.6. Valores ausentes, ceros y preparación de métricas

La preparación conserva la diferencia entre una cantidad cero y una comparación que no puede calcularse:

Situación	Tratamiento	Interpretación
Territorio sin afectaciones dentro de un intervalo con cobertura diaria disponible	Conteos de cero, cuando ese territorio forma parte de las zonas comparadas.	Ausencia de afectaciones enlazadas en ese intervalo y conjunto; no demuestra ausencia de fallas reales.
Año o intervalo sin la cobertura diaria requerida	Métricas o comparaciones vacías; estado de falta de cobertura cuando corresponda.	Dato no disponible para la comparación. No se rellena como cero.
Referencia histórica igual a cero	Diferencia absoluta cuando ambos valores existen; variación porcentual vacía.	No se divide entre cero ni se presenta un porcentaje infinito.
Cliente sin fallas registradas en uno de los años, con cobertura disponible	Cero en el conteo anual de ese identificador.	No acredita que tuviera servicio activo ese año.
Repetición media sin clientes afectados	Valor vacío al no existir denominador positivo.	No se construye una tasa con denominador cero.
Promedio histórico con un año sin cobertura	Valor vacío.	No se sustituye el promedio de 2024 y 2025 por un promedio de

Situación	Tratamiento	Interpretación
		una sola referencia.

Los conteos distintos se recalculan en cada intervalo y agrupación. Los totales nacionales se obtienen directamente del conjunto nacional: no se suman clientes distintos de territorios, días o partidos solapados. La preparación no imputa afectaciones, no modifica su territorio para mejorar el resultado y no agrega una cartera de clientes activos que no existe en estas fuentes.

Estas reglas están en `comparar_metricas`, `comparar_intervalos`, `exportar_fallas_por_cliente`, `cuenta_ventana` y `cuenta_intervalo_todos` de [src/analisis.py](#). Desarrollo la configuración de algoritmos y la sensibilidad de los umbrales en la sección 10.

6.7. Alcance de la limpieza y límites documentales

Documento los archivos elegibles, la conversión local, los límites temporales, la deduplicación y las unidades de conteo. Concilio los volúmenes comprobables del control y los agregados de clientes con el nacional. La limpieza operativa y la comparación quedan definidas para su reproducción.

No dispongo del desglose de fechas ilegibles excluidas antes de la carga ni de las versiones competidoras que una deduplicación pudiera descartar. Esos límites afectan una auditoría integral de la historia, no justifican rellenar métricas indefinidas ni cambiar la comparación solicitada. Si aparecieran llaves repetidas con atributos distintos necesitaría registrar ambas versiones y confirmar la prioridad empresarial.

Utilizo los [SQL generales](#) y [de clientes](#), la [configuración](#), la [descarga](#), el [análisis](#), [main.py](#), el [control](#) y la [guía de reproducción](#). Mantengo las limitaciones de población, selección y trazabilidad explicadas en las secciones 3 a 5.

7. Análisis exploratorio de datos

7.1. Propósito y momento del EDA

En mi EDA examino la calidad de las salidas, el volumen y la repetición de afectaciones, la evolución diaria y la heterogeneidad territorial. También reviso las escalas y relaciones de las tres variables que utiliza el detector. Busco reconocer patrones y límites que orienten la interpretación de la comparación histórica.

Organizo esta exploración a partir de una ejecución ya disponible. No afirmo que estos gráficos hayan sido elaborados antes de configurar el detector ni que los hallazgos hayan calibrado sus parámetros. Explico qué aspectos me llevan a revisar por día y territorio, distinguir ceros de comparaciones indefinidas y ser prudente con las alertas. Desarrollo la

justificación y la sensibilidad del algoritmo en la sección 10; la calibración con eventos confirmados sigue fuera de la evidencia disponible.

Mantengo las mismas fechas y horas locales en 2024, 2025 y 2026. No sustituyo las referencias por otros periodos ni ajusto al mismo día de la semana. Los conteos describen afectaciones registradas y enlazadas; no son tasas sobre clientes activos ni una medición directa de ViX.

7.2. Fuentes, unidades y reproducción

Recalculo las tablas y las figuras desde estas salidas, sin volver a ejecutar `main.py` :

Fuente relativa a la raíz	Unidad de cada fila	Utilización en mi EDA
<code>resultados/comparacion_periodo_zona.csv</code>	Periodo completo–nivel–zona.	Volumen, repetición media y diferencias territoriales.
<code>resultados/comparacion_diaria_zona.csv</code>	Fecha local–nivel–zona.	Evolución y distribución de los 39 días por año.
<code>resultados/comparacion_por_partido_zona.csv</code>	Partido–nivel–zona.	Perfil de las variables, referencias y estados del detector.
<code>resultados/control_calidad.json</code>	Controles de la carga y de los cruces.	Presencia diaria y alcance de la calidad documentada.
<code>resultados/resumen_ejecucion.json</code>	Resumen de la ejecución guardada.	Conciliación de filas, partidos y alertas.
<code>config.json</code> y <code>src/analisis.py</code>	Parámetros vigentes y comportamiento del programa.	Contraste de periodos, referencias y cálculo de los estados.

Utilizo exclusivamente las filas `NIVEL = NACIONAL` para las gráficas y las relaciones nacionales. El total de clientes distintos del periodo procede de su propia fila nacional; no lo obtengo sumando días, entidades o ventanas. Las 104 ventanas de partidos incluyen horarios repetidos y solapamientos, por lo que no representan 104 observaciones independientes.

En las celdas compruebo la concordancia de configuración y resumen, las llaves de las tablas, los promedios de los dos años, los denominadores cero, las fechas de la serie y los estados guardados. Estas comprobaciones validan la consistencia de las salidas utilizadas; no demuestran que la fuente contenga todas las fallas reales ni autentican retrospectivamente cada parámetro de la ejecución. Registro nombres, tamaños y SHA-256 en [el manifiesto del EDA](#).

```
In [51]: from pathlib import Path
import sys
sys.dont_write_bytecode = True

# Localizo los scripts comunes sin buscar ni abrir otro notebook.
raiz = next((p for p in (Path.cwd(), *Path.cwd().parents)
              if (p / 'config.json').is_file()
              and (p / 'proyecto/eda.py').is_file()
              and (p / 'proyecto/revision.py').is_file()), None)
if raiz is None:
    raise FileNotFoundError('Abro este notebook dentro del proyecto que contiene co
if str(raiz) not in sys.path:
    sys.path.insert(0, str(raiz))

import matplotlib.pyplot as plt
from IPython.display import Markdown, display
%matplotlib inline
from proyecto.eda import (
    cargar_salidas, elaborar_perfil, exportar_perfil, formato, tabla_markdown,
    grafica_evolucion, grafica_distribucion, guardar_figura,
)

datos = cargar_salidas(raiz)
perfil = elaborar_perfil(datos)
recursos = raiz / 'proyecto/recursos_2'
exportar_perfil(datos, perfil, recursos)
display(Markdown(
    f"Compruebo **{formato(len(datos['periodo']))} filas del periodo**, "
    f"**{formato(len(datos['diario']))} filas diarias** y "
    f"**{formato(len(datos['partidos']))} filas partido-nivel-zona**. "
    f"Mi serie nacional contiene **{len(datos['nacional_diario'])} días**."
))
```

Compruebo **330 filas del periodo, 11.899 filas diarias y 24.269 filas partido-nivel-zona**. Mi serie nacional contiene **39 días**.

7.3. Perfil de faltantes, ceros y cobertura

Retomo la auditoría de la sección 6: el control de calidad registra cero filas de clientes omitidas por campos obligatorios incompletos, cero regiones sin catálogo y cero afectaciones sin incidencia general. En los 39 días analíticos de cada año hay presencia de clientes, incidencias generales y cruce. La consulta documentada en 6.5 encontró **0 MAC nulas o vacías entre 24.674.207 filas cargadas**. Ese perfil previo corresponde al índice aceptado y deduplicado; no lo generalizo a las filas excluidas ni a la historia original.

Para ampliar el perfil cuantifico los valores vacíos y los ceros de las **salidas agregadas**. Cuento filas por unidad de cada tabla y verifico los denominadores. En la columna de conteos vacíos examino las cuatro métricas actuales; además compruebo que sus conteos de 2024 y 2025 estén informados.

```
In [52]: display(Markdown(tabla_markdown(
    ["Tabla", "Filas", "Algún conteo actual vacío", "Clientes 2026 = 0",
     "Repetición media vacía", "Variación de clientes vacía", "% de filas con varia
    [[p['tabla'], formato(p['filas']), formato(p['conteos_vacios']),
     formato(p['sin_clientes_2026']), formato(p['repeticion_media_vacia']),
     formato(p['porcentaje_clientes_vacio']), formato(p['porcentaje_vacio_pct_fila
    for p in perfil['faltantes']],
    )))
```

Tabla	Filas	Algún conteo actual vacío	Clientes 2026 = 0	Repetición media vacía	Variación de clientes vacía	% de filas con variación vacía
periodo	330	0	2	2	2	0,61 %
diario	11.899	0	1.718	1.718	548	4,61 %
partidos	24.269	0	6.639	6.639	3.020	12,44 %

```
In [53]: p_periodo, p_diario, p_partidos = perfil['faltantes']
display(Markdown(
    f"Encuentro **{formato(sum(p['conteos_vacios'] for p in perfil['faltantes']))}
    f"En 2026 hay **{formato(p_diario['sin_clientes_2026'])} filas diarias** y "
    f"***{formato(p_partidos['sin_clientes_2026'])} filas de partido** sin clientes;
    f"en el periodo son **{formato(p_periodo['sin_clientes_2026'])}**. "
    "En esas filas la repetición media queda indefinida por falta de denominador po
    f"La variación de clientes frente al histórico queda vacía en **{formato(p_peri
    f"***{formato(p_diario['porcentaje_clientes_vacio'])} diarias** y **{formato(p_p
    "Compruebo que la referencia es cero; conservo conteos y diferencias absolutas
    "Distingo el cero registrado de la comparación indefinida. La cobertura global
    "actividad del servicio ni estabilidad del catálogo. Esta evidencia tampoco ide
    ))
```

Encuentro **0 filas con conteos actuales vacíos**. En 2026 hay **1.718 filas diarias** y **6.639 filas de partido** sin clientes; en el periodo son **2**. En esas filas la repetición media queda indefinida por falta de denominador positivo.

La variación de clientes frente al histórico queda vacía en **2 filas del periodo, 548 diarias** y **3.020 de partido**. Compruebo que la referencia es cero; conservo conteos y diferencias absolutas sin imputar un porcentaje.

Distingo el cero registrado de la comparación indefinida. La cobertura global no garantiza exhaustividad territorial, actividad del servicio ni estabilidad del catálogo. Esta evidencia tampoco identifica las fechas ilegibles excluidas antes de la carga.

7.4. Volumen nacional y repetición de las afectaciones

Parto de la fila nacional del **periodo completo**, con unidades distintas para clientes, incidencias, MAC y pares cliente–incidencia. Comparo 2026 con cada año y con el promedio aritmético de 2024 y 2025.

```
In [54]: nacional = datos['nacional']
etiquetas = {
    'CLIENTES_DISTINTOS': 'Clientes afectados distintos',
    'INCIDENCIAS_DISTINTAS': 'Incidencias distintas asociadas a clientes',
    'MAC_DISTINTAS': 'MAC distintas',
    'FALLAS_CLIENTE': 'Pares distintos cliente–incidencia',
}
display(Markdown(tabla_markdown(
    ['Métrica', '2024', '2025', '2026', 'Promedio histórico', 'Cambio frente al his
    [[etiqueta, formato(nacional[metrica+'_2024']), formato(nacional[metrica+'_2025
    formato(nacional[metrica]), formato(nacional['PROMEDIO_HISTORICO_'+metrica]),
    formato(nacional['VAR_'+metrica+'_PCT_VS_HISTORICO'], 2)+' %']
    for metrica, etiqueta in etiquetas.items()),
)))
display(Markdown(tabla_markdown(
    ['Métrica', '2024', '2025', '2026'],
    [['Fallas por cliente afectado', formato(nacional['FALLAS_PROMEDIO_POR_CLIENTE_
    formato(nacional['FALLAS_PROMEDIO_POR_CLIENTE_2025'], 4),
    formato(nacional['FALLAS_PROMEDIO_POR_CLIENTE'], 4)]]),
)))
```

Métrica	2024	2025	2026	Promedio histórico	Cambio frente al histórico
Clientes afectados distintos	3.160.907	2.850.489	3.346.873	3.005.698	11,35 %
Incidencias distintas asociadas a clientes	124.795	114.157	182.116	119.476	52,43 %
MAC distintas	3.770.229	3.260.411	3.718.749	3.515.320	5,79 %
Pares distintos cliente–incidencia	6.933.682	6.179.984	8.711.270	6.556.833	32,86 %

Métrica	2024	2025	2026
Fallas por cliente afectado	2,1936	2,1680	2,6028

```
In [55]: display(Markdown(
    f"Observo **{formato(nacional['CLIENTES_DISTINTOS'])} clientes afectados distin
    f"frente a **{formato(nacional['PROMEDIO_HISTORICO_CLIENTES_DISTINTOS'])}** de
    f"la variación es **{formato(nacional['VAR_CLIENTES_DISTINTOS_PCT_VS_HISTORICO'
    f"Los pares varían **{formato(nacional['VAR_FALLAS_CLIENTE_PCT_VS_HISTORICO'],
    f"***{formato(nacional['VAR_INCIDENCIAS_DISTINTAS_PCT_VS_HISTORICO'], 2)}**."
    f"La repetición media es **{formato(nacional['FALLAS_PROMEDIO_POR_CLIENTE'], 4)
    f"frente a **{formato(nacional['FALLAS_PROMEDIO_POR_CLIENTE_2024'], 4)}** y "
    f"***{formato(nacional['FALLAS_PROMEDIO_POR_CLIENTE_2025'], 4)}** en los dos año
    "Examino alcance y repetición conjuntamente. No interpreto pares como eventos g
```

```
"ni estas razones como tasas sobre cartera activa, duración, severidad o causas
))
```


Observo **3.346.873 clientes afectados distintos** en 2026, frente a **3.005.698** de promedio histórico: la variación es **11,35 %**. Los pares varían **32,86 %** y las incidencias **52,43 %**. La repetición media es **2,6028** en 2026, frente a **2,1936** y **2,1680** en los dos años anteriores.

Examino alcance y repetición conjuntamente. No interpreto pares como eventos generales independientes ni estas razones como tasas sobre cartera activa, duración, severidad o causas.

7.5. Evolución diaria: primera gráfica

Comparo clientes afectados por día en 2024, 2025 y 2026, alineados por mes y día en hora de México. La línea discontinua muestra el promedio de los dos históricos. Utilizo **clientes distintos del día**, no filas físicas de afectaciones ni clientes únicos del periodo.

```
In [56]: figura_evolucion = grafica_evolucion(datos)
guardar_figura(figura_evolucion, recursos, 'evolucion_clientes_diaria')
display(figura_evolucion)
plt.close(figura_evolucion)
```



```
In [57]: pico = perfil['pico_clientes']
dia_18 = next(f for f in datos['nacional_diario'] if f['FECHA_MX'] == '2026-06-18')
display(Markdown(
    f"Identifico el máximo de 2026 el **{pico['FECHA_MX']}**, con **{formato(pico['FECHA_MX'], 2)}** y una variación de **{formato(pico['VAR_CLIENTES_DISTINTOS_PCT_VS_HISTORICO'], 2)}** %".
    f"El 18 de junio tiene **{formato(dia_18['CLIENTES_DISTINTOS'], 2)}** clientes** y "
    f"**{formato(dia_18['VAR_CLIENTES_DISTINTOS_PCT_VS_HISTORICO'], 2)}** de variación".
    f"Observo clientes por encima del histórico en **{perfil['dias_clientes_sobre_historico']}** días".
    f"Conservo la comparación diaria para ubicar incidencias y territorios antes de los partidos".
    f"La coincidencia con partidos no establece un efecto del Mundial ni una falla de cobertura".
    f"Conservo la [figura PNG](recursos_2/evolucion_clientes_diaria.png) y la [figura PNG](recursos_2/evolucion_clientes_diaria.png)"
))
```

Identifico el máximo de 2026 el **2026-06-19**, con **470.775 clientes**, y una variación de **173,69 %** frente a sus referencias. El 18 de junio tiene **356.100 clientes** y **159,33 %** de variación. Observo clientes por encima del histórico en **32 de 39 días**.

Conservo la comparación diaria para ubicar incidencias y territorios antes de explicar los picos. La coincidencia con partidos no establece un efecto del Mundial ni una falla de ViX. No sumo clientes diarios para obtener el total del periodo.

Conservo la [figura PNG](#) y la [figura SVG](#).


7.6. Distribución diaria: segunda gráfica

Examino los **39 conteos nacionales diarios** de cada año. La caja abarca del primer al tercer cuartil y su línea central representa la mediana. Los bigotes llegan a los valores observados dentro de 1,5 veces el rango intercuartílico; muestro todos los días como puntos, incluidos los que quedan fuera de los bigotes. El desplazamiento horizontal de los puntos sólo permite distinguirlos y no representa otra variable.

Calculo los cuartiles por interpolación lineal con el criterio `inclusive` de `statistics.quantiles`. Un punto fuera de los bigotes es un valor extremo bajo esa regla descriptiva; no equivale a `ANOMALIA` del detector KNN.

```
In [58]: display(Markdown(tabla_markdown(
    ['Año', 'Días', 'Mínimo', 'Q1', 'Mediana', 'Q3', 'Máximo'],
    [[p['anio'], p['dias'], formato(p['minimo']), formato(p['q1'], 1),
      formato(p['mediana']), formato(p['q3'], 1), formato(p['maximo'])]
      for p in perfil['distribucion_diaria']]),
    ))
figura_distribucion = grafica_distribucion(datos)
guardar_figura(figura_distribucion, recursos, 'distribucion_clientes_diaria')
display(figura_distribucion)
plt.close(figura_distribucion)
```

Año	Días	Mínimo	Q1	Mediana	Q3	Máximo
2024	39	82.862	133.017,5	156.435	176.855,5	336.846
2025	39	94.452	117.810,5	136.337	146.110,0	282.720
2026	39	113.175	168.082,5	188.049	208.395,5	470.775



```
In [59]: dist = {p['anio']: p for p in perfil['distribucion_diaria']}
display(Markdown(
    f"Observo una mediana diaria de **{formato(dist[2026]['mediana'])} clientes en"
    f"frente a **{formato(dist[2024]['mediana'])} en 2024** y **{formato(dist[2025]"
    f"La mitad central de los días de 2026 está entre **{formato(dist[2026]['q1'],"
    f"**{formato(dist[2026]['q3'], 1)} clientes**. Su máximo es **{formato(dist[2026]"
    "Distingo el comportamiento central de los picos sin calcular significancia a p"
    "las fechas consecutivas pueden ser dependientes y no tengo denominadores de ex"
    "Conservo la [figura PNG](recursos_2/distribucion_clientes_diaria.png) y su [ve"
    ))
```

Observo una mediana diaria de **188.049 clientes en 2026**, frente a **156.435 en 2024** y **136.337 en 2025**. La mitad central de los días de 2026 está entre **168.082,5** y **208.395,5 clientes**. Su máximo es **470.775**.

Distingo el comportamiento central de los picos sin calcular significancia a partir de las cajas: las fechas consecutivas pueden ser dependientes y no tengo denominadores de exposición.

Conservo la [figura PNG](#) y su [versión SVG](#).

7.7. Heterogeneidad territorial y variables del detector

Ordeno las entidades por la **diferencia absoluta de pares cliente–incidencia** frente al promedio histórico del periodo. Muestro las cinco mayores diferencias positivas para examinar dónde revisar el aumento; no construyo el total nacional sumando conteos distintos territoriales.

```
In [60]: display(Markdown(tabla_markdown(
    ['Entidad según el catálogo', 'Pares en 2026', 'Promedio histórico', 'Diferenci"
    [[f['ZONA'], formato(f['FALLAS_CLIENTE']), formato(f['PROMEDIO_HISTORICO_FALLAS
```

```

        formato(f['DIF_FALLAS_CLIENTE_VS_HISTORICO'], 1),
        formato(f['VAR_FALLAS_CLIENTE_PCT_VS_HISTORICO'], 2)+' %']
    for f in perfil['entidades_top5']],
)))
display(Markdown(tabla_markdown(
    ['Variable del detector', 'Ventanas nacionales', 'Mínimo 2026', 'Mediana 2026',
    [[p['variable'], p['ventanas'], formato(p['minimo']), formato(p['mediana']), fo
    for p in perfil['perfil_variables_ventanas']],
)))
display(Markdown(tabla_markdown(
    ['Relación descriptiva en las 104 ventanas nacionales', 'Correlación de Pearson
    [['Clientes e incidencias', formato(perfil['correlaciones_ventanas']['INCIDENCI
    ['Clientes y MAC', formato(perfil['correlaciones_ventanas']['MAC_DISTINTAS'],
    ))

```

Entidad según el catálogo	Pares en 2026	Promedio histórico	Diferencia	Variación
NUEVO LEON	1.771.424	993.636,5	777.787,5	78,28 %
CIUDAD DE MEXICO	1.663.504	1.162.302,5	501.201,5	43,12 %
MEXICO	905.101	722.570,0	182.531,0	25,26 %
TAMAULIPAS	611.750	469.349,0	142.401,0	30,34 %
SAN LUIS POTOSI	147.179	78.994,5	68.184,5	86,32 %

Variable del detector	Ventanas nacionales	Mínimo 2026	Mediana 2026	Máximo 2026
CLIENTES_DISTINTOS	104	15.410	35.878	235.458
INCIDENCIAS_DISTINTAS	104	290	801	3.823
MAC_DISTINTAS	104	17.361	39.339	255.291

Relación descriptiva en las 104 ventanas nacionales	Correlación de Pearson
Clientes e incidencias	0,9337
Clientes y MAC	0,9990

```

In [61]: entidades = [f for f in datos['periodo'] if f['NIVEL'] == 'ENTIDAD_FEDERATIVA']
aumentos_entidades = sum(float(f['DIF_FALLAS_CLIENTE_VS_HISTORICO']) > 0 for f in e
primeras = perfil['entidades_top5'][:2]
contraste_entidades = '; '.join(
    f"{f['ZONA']}: {formato(f['DIF_FALLAS_CLIENTE_VS_HISTORICO'], 1)} pares adicion
    for f in primeras)
display(Markdown(
    f"Encuentro aumento de pares en **{aumentos_entidades} de {len(entidades)} enti
    f"Las mayores diferencias absolutas son **{contraste_entidades}**. "
    "Las fracciones proceden del promedio de dos conteos enteros. Uso estos resulta
    "sin convertirlos en probabilidades de falla ni en una clasificación de calidad
    f"La correlación descriptiva entre clientes e incidencias es **{formato(perfil[
    f"y entre clientes y MAC, **{formato(perfil['correlaciones_ventanas']['MAC_DIST
    "Señalo posible redundancia entre alcance en clientes y dispositivos. No elimin
    "a partir de ventanas repetidas o solapadas; explico la escala y la sensibiliba
    ))

```

Encuentro aumento de pares en **28 de 32 entidades**. Las mayores diferencias absolutas son **NUEVO LEON: 777.787,5 pares adicionales; CIUDAD DE MEXICO: 501.201,5 pares adicionales**. Las fracciones proceden del promedio de dos conteos enteros. Uso estos resultados para orientar la revisión territorial, sin convertirlos en probabilidades de falla ni en una clasificación de calidad de toda la red.

La correlación descriptiva entre clientes e incidencias es **0,9337**, y entre clientes y MAC, **0,9990**. Señalo posible redundancia entre alcance en clientes y dispositivos. No elimino variables ni infiero causalidad a partir de ventanas repetidas o solapadas; explico la escala y la sensibilidad en la sección 10.

7.8. Cómo orienta el EDA mi análisis

Hallazgo que documento	Cómo orienta mi lectura y revisión
Clientes distintos, incidencias y pares evolucionan con magnitudes diferentes.	Mantengo las unidades separadas y examino alcance y repetición conjuntamente.
Diferencias diarias y picos identificados en las tablas.	Conservo la comparación diaria y localizo incidencias y territorios en esos días antes de formular una explicación.
Mediana diaria mayor en 2026, además de valores extremos.	Distingo el centro de la distribución de sus máximos y evito apoyar toda la lectura en un solo pico.
Aumentos y descensos territoriales distintos.	Reviso diferencias absolutas y relativas por territorio; el agregado nacional no describe por sí solo cada zona.
Porcentajes y repetición media vacíos por denominadores cero.	Conservo las métricas indefinidas y uso conteos y diferencias absolutas; no relleno con ceros.
Escalas diferentes y fuerte asociación entre clientes y MAC.	Reviso la normalización y señalo una posible redundancia para evaluar el detector en la sección 10.
Dos referencias históricas por ventana.	Presento sus clasificaciones como candidatos de investigación y mantengo la necesidad de validación independiente.

Mi EDA aporta descripciones y prioridades de revisión. No confirma casos de falla de ViX, causas raíz, ahorro operativo, significancia de las diferencias ni fiabilidad predictiva del detector. Defino mi decisión académica y mis criterios de revisión en la sección 12. No atribuyo a una organización la ejecución de esas recomendaciones.

Las tablas y las figuras corresponden a las salidas identificadas en el manifiesto. Al regenerar las salidas vuelvo a ejecutar las celdas: sus cifras e interpretaciones cuantitativas se calculan desde los datos disponibles. Mantengo el alcance y los límites de esta comparación histórica. Conservo el [perfil calculado](#) y el [código de reproducción](#).

8. Tipo de enfoque

8.1. Declaración del enfoque

En mi proyecto utilizo un **enfoque no supervisado de detección de anomalías por distancia a vecinos más cercanos (KNN)**, acompañado de reglas de magnitud y umbrales. También realizo una comparación histórica descriptiva. No utilizo una clasificación KNN entrenada con ejemplos etiquetados de falla confirmada o comportamiento normal.

La entrada del detector es un vector de **clientes distintos, incidencias distintas y MAC distintas**, para cada combinación partido–nivel–zona. Construyo su referencia con las mismas fechas y horas locales de **2024 y 2025**. `FALLAS_CLIENTE` ayuda a describir repetición, pero no integra ese vector de distancia.

Las referencias históricas son observaciones de comparación, **sin etiquetas validadas de normalidad**. La expresión «ventanas normales» en el comentario de `evaluar` describe su función técnica como referencia; no demuestra que esos intervalos estuvieran libres de problemas.

8.2. De las observaciones a una clasificación generada

Reviso el procedimiento de `evaluar` y `analizar` en [src/analysis.py](#):

1. Cuento las tres variables de 2026 y sus referencias históricas para el mismo territorio e intervalo.
2. Centro y escalo cada variable con las referencias de esa comparación, utilizando la mediana, la dispersión absoluta mediana y los límites mínimos que establece el programa.
3. Calculo la distancia euclidiana a los vecinos históricos y la comparo con las distancias entre referencias, excluyendo la propia observación.
4. Combino distancia y puntuación con los filtros de clientes afectados, exceso de clientes y percentiles históricos.
5. Genero el campo `ESTADO` a partir de esos criterios y de la disponibilidad de referencias y cobertura.

ANOMALIA es una clasificación producida por mi procedimiento, no una etiqueta de verdad previamente validada. El campo no identifica por sí solo una causa raíz, una falla de ViX o un deterioro atribuible al Mundial. Tampoco representa una probabilidad de falla.

Estado generado	Cómo lo interpreto
<code>ANOMALIA</code>	Se cumplen todos los filtros vigentes; obtengo un candidato para investigación.
<code>ESPERADO</code>	No se cumplen todos los filtros de alerta; no pruebo normalidad ni ausencia de afectaciones.
<code>SIN_BASE</code>	No reúno el mínimo requerido de referencias para evaluar la distancia.

SIN_COBERTURA No dispongo de la cobertura de datos requerida para esa comparación.

No utilizo estas clasificaciones como etiquetas independientes para demostrar la calidad del mismo detector. Una validación requiere evidencia externa al procedimiento que las generó.

```
In [62]: from collections import Counter
estados = Counter(f['ESTADO'] for f in datos['partidos'])
referencias = sorted({int(f['N_REFERENCIAS']) for f in datos['partidos']})
display(Markdown(
    '### 8.3. Ejecución documentada y límite de las referencias\n\n'
    f'Utilizo **k={datos["conf"]['k_vecinos_distancia']}** y un mínimo de "
    f"**{datos["conf"]['minimo_ventanas_comparables']} referencias**."
    f"Los números de referencias presentes son **{referencias}**."
    f'Obtengo **{formato(estados["ANOMALIA"])} ANOMALIA**, **{formato(estados["ESPE"
    f"**{formato(estados["SIN_BASE"])} SIN_BASE** y **{formato(estados["SIN_COBERTU"
    "Estos estados cuentan clasificaciones por ventana y territorio, no eventos ind
    "El mínimo técnico permite calcular distancias, pero no demuestra calibración e
    "Con dos referencias y k=1, las dos distancias base son iguales y su MAD vale c
    "el denominador mínimo queda en uno. La puntuación no es una probabilidad ni un
    "Mantengo separadas consistencia técnica, descripción del extracto y validación
    ))
```

8.3. Ejecución documentada y límite de las referencias

Utilizo **k=1** y un mínimo de **2 referencias**. Los números de referencias presentes son **[2]**.
Obtengo **6.393 ANOMALIA, 17.876 ESPERADO, 0 SIN_BASE** y **0 SIN_COBERTURA**.

Estos estados cuentan clasificaciones por ventana y territorio, no eventos independientes. El mínimo técnico permite calcular distancias, pero no demuestra calibración estadística. Con dos referencias y k=1, las dos distancias base son iguales y su MAD vale cero; el denominador mínimo queda en uno. La puntuación no es una probabilidad ni un número de desviaciones estándar. Mantengo separadas consistencia técnica, descripción del extracto y validación independiente.

8.4. Alcance metodológico y evidencia disponible

Compruebo la reproducción técnica del detector en la sección 10 y describo sus candidatos en la sección 11. No entreno un clasificador supervisado, por lo que explico en la sección 9 por qué una partición convencional no corresponde a este diseño.

Para validar la utilidad del detector necesitaría casos confirmados y una revisión independiente de ventanas alertadas y no alertadas. No dispongo de esa verdad externa y no reporto precisión, sensibilidad o acierto predictivo. La sensibilidad que ya ejecuto describe dependencia de parámetros; no sustituye la validación operativa.

Utilizo la [configuración](#), el [programa](#), el [control](#), el [resumen](#), los [agregados del periodo](#), los [diarios](#), los [de partido](#), el [código de EDA](#) y su [manifiesto vigente](#).

Continúo el estudio desde la exploración hacia su comprobación y decisión. En las secciones 9 y 10 delimito la validación y el algoritmo; en 11 integro los resultados; en 12 a 15 explico qué decido, qué aporta el análisis y qué conclusiones admite su evidencia.

Recalculo aritmética, campos del evaluador, selección de alertas y recurrencia desde las salidas de `main.py`. No reconstruyo una ejecución histórica a partir de informes ausentes. Mi propósito es una evaluación académica del comportamiento registrado de izzi y de los límites de la atribución al Mundial.

9. Entrenamiento y prueba supervisados

9.1. Por qué no aplico una partición supervisada

No entreno un clasificador con ejemplos previamente etiquetados como falla anómala o comportamiento normal. Mi procedimiento compara el vector de 2026 con dos vectores históricos por territorio y ventana, estima su escala y aplica distancias y reglas. No ajusto coeficientes mediante una función de pérdida supervisada. Por eso **el requisito de entrenamiento y prueba supervisados no aplica** a este diseño. Las referencias de 2024 y 2025 intervienen en el cálculo del detector; no las presento como una prueba independiente ni como normalidad confirmada. `ANOMALIA` y `ESPERADO` son resultados de reglas, no etiquetas de verdad.

Tampoco divido aleatoriamente las filas de partido para fabricar una validación: partidos simultáneos, ventanas superpuestas y niveles territoriales comparten afectaciones. Una separación por filas podría colocar el mismo evento a ambos lados y dar una impresión engañosa de independencia.

9.2. Cómo planteo la validación independiente pendiente

Para una validación futura propongo contrastar ventanas alertadas y no alertadas con una revisión operativa independiente de incidencias, causas, duración y severidad. Primero necesitaría acordar el criterio de evento relevante con la fuente organizacional; no invento ese criterio ni doy por confirmados los candidatos. Propongo incluir referencias cero, referencias pequeñas y positivas y todos los niveles geográficos, registrar cómo selecciono los casos y mantener agrupado cada evento compartido entre ventanas. Una revisión sólo de las alertas impediría evaluar las omisiones del detector.

Separaría la selección de umbrales de su evaluación final y reservaría eventos o periodos independientes para esta última. Si llegara a desarrollar un modelo supervisado, definiría entonces su separación temporal y por evento, sin utilizar el conjunto de evaluación para

calibrarlo. Es una propuesta futura; no la reporto como ejecutada ni altero la comparación actual de las mismas fechas.

Con casos confirmados podría estimar precisión $VP/(VP+FP)$ y sensibilidad $VP/(VP+FN)$, documentando la selección y el denominador. Hoy no conozco VP, FP ni FN: **esas métricas no son calculables**. Mis comprobaciones de aritmética, reproducción del evaluador y pruebas de código acreditan consistencia técnica; no sustituyen la validación independiente del detector.

10. Algoritmo y parámetros

10.1. Por qué utilizo distancia KNN y estas variables

Utilizo el evaluador KNN implementado en [el programa](#) como una herramienta exploratoria interpretable: comparo una ventana con sus referencias y puedo rastrear cómo se genera un candidato. La ausencia de etiquetas explica el enfoque no supervisado. No afirmo que KNN supere a otros métodos: no dispongo de una evaluación comparativa con eventos confirmados.

Mi vector es **(clientes distintos, incidencias distintas, MAC distintas)**. Con clientes describo el alcance registrado; con incidencias, la cantidad de eventos generales enlazados; con MAC, el alcance entre dispositivos identificados. Las unidades son diferentes y por eso normalizo cada componente. No añado `FALLAS_CLIENTE` al vector: lo utilizo descriptivamente para medir pares y recurrencia. En la sección 7 cuantifico la correlación descriptiva entre clientes y MAC en las ventanas nacionales. Reconozco posible redundancia y un mayor peso implícito del alcance; no la convierto en prueba de selección óptima de variables. La ablación de variables y la validación de su aportación quedan pendientes.

10.2. Cómo reproduzco el cálculo

Para las dos referencias (r_{2024}, r_{2025}) , calculo por componente (j) :

$$c_j = \text{mediana}(r_{2024,j}, r_{2025,j}), \quad MAD_j = \text{mediana}(|r_{a,j} - c_j|), \quad s_j = \max(1, 1,4826$$

Transformo cada vector como $(z_j = (x_j - c_j)/s_j)$. Calculo la distancia euclídea de 2026 a cada referencia y promedio sus (k) distancias menores. Para cada referencia calculo también la distancia a sus vecinos excluyéndose a sí misma. Con esas distancias base (D_a) obtengo:

$$S = \frac{D_{2026} - \text{mediana}(D_a)}{\max(1, 1,4826 \text{ mediana}(|D_a - \text{mediana}(D_a)|))}.$$

Clasifico como **ANOMALIA** sólo si se cumplen simultáneamente: clientes de 2026 ≥ 10 ; exceso sobre la mediana histórica ≥ 10 ; clientes de 2026 estrictamente mayores que el P95 histórico de clientes; distancia actual estrictamente mayor que el P95 de las distancias base; y **S** ≥ 3 . El P95 de clientes se redondea a dos decimales antes de la comparación, de acuerdo

con el código. No interpreto ese percentil con dos observaciones como una prueba de significancia.

Con dos referencias y $k=1$, las dos distancias base son iguales; su MAD vale cero y el denominador de S queda en uno. Si ambos históricos tienen cero clientes, las tres variables históricas son cero, la escala es uno y una observación actual con al menos diez clientes satisface las reglas vigentes. Por eso una puntuación muy alta puede resultar de la escala y de referencias cero; **S no es una probabilidad ni un número de desviaciones estándar.**

```
In [63]: conf = datos['conf']
display(Markdown('### 10.3. Parámetros vigentes y alcance de su justificación\n\n'
['Parámetro', 'Valor vigente', 'Razón técnica y límite'],
[
['Fechas', conf['inicio_analisis'] + ' a ' + conf['fin_analisis'], 'Comparo
['Mínimo de referencias', conf['minimo_ventanas_comparables'], 'El mínimo t
['Vecinos k', conf['k_vecinos_distancia'], 'Con dos controles sólo hay un v
['Ventana', f"-{conf['minutos_antes']}/{conf['minutos_despues']} minutos",
['Clientes mínimos', conf['minimo_clientes_anomalia'], 'Filtro magnitudes p
['Exceso mínimo', conf['minimo_exceso_clientes'], 'Exijo un aumento absolut
['Puntuación mínima', conf['minimo_puntuacion_distancia'], 'No la interpret
['Escala', 'max(1, 1,4826 MAD, raíz(media+1))', 'Evito divisiones por cer
]
)))
display(Markdown(
'### 10.4. Comprobación y sensibilidad reproducibles\n\n'
'Recalculo el evaluador desde los CSV agregados y varío un parámetro a la vez,
'Mantengo las fechas, ventanas y conteos. La sensibilidad no determina parámetr
'Para justificar otras duraciones necesitaría reconstruir intervalos desde regi
))
```

10.3. Parámetros vigentes y alcance de su justificación

Parámetro	Valor vigente	Razón técnica y límite
Fechas	2026-06-11 a 2026-07-19	Comparo las mismas fechas y horas de 2024 y 2025.
Mínimo de referencias	2	El mínimo técnico no demuestra suficiencia estadística.
Vecinos k	1	Con dos controles sólo hay un vecino distinto de cada referencia.
Ventana	-30/+180 minutos	Excluyo el final; no mido exposición ni duración real del partido.
Cientes mínimos	10	Filtro magnitudes pequeñas sin una calibración empresarial.
Exceso mínimo	10	Exijo un aumento absoluto según la regla configurada.
Puntuación mínima	3.0	No la interpreto como probabilidad o número de sigmas.
Escala	$\max(1, 1,4826 \text{ MAD}, \text{raíz}(\text{mediana}+1))$	Evito divisiones por cero y el predominio de las unidades grandes.

10.4. Comprobación y sensibilidad reproducibles

Recalculo el evaluador desde los CSV agregados y varío un parámetro a la vez, salvo el escenario explícito de seis referencias y $k=3$. Mantengo las fechas, ventanas y conteos. La sensibilidad no determina parámetros óptimos ni calibra el detector. Para justificar otras duraciones necesitaría reconstruir intervalos desde registros temporales detallados y contrastarlos con demanda y eventos confirmados.

```
In [64]: from proyecto.revision import revisar, exportar
revision = revisar(raiz)
for escenario in revision['sensibilidad']:
    if escenario['minimo_referencias'] == 6:
        escenario['escenario'] = 'Escenario: 6 referencias, k=3'
exportar(revision, recursos)
datos = revision['datos']
indicadores = revision['indicadores']
comprobaciones = revision['verificacion']
display(Markdown(
    f"Compruebo **{formato(comprobaciones['filas_aritmetica'])} filas** en su aritm
    f"reproduzco **{formato(comprobaciones['evaluaciones_recalculadas'])} evaluacio
    f"Recalculo **{formato(comprobaciones['filas_clientes_recalculadas'])} filas po
    'La selección y el orden de las alertas coinciden exactamente con el CSV guarda
    ))
```

Compruebo **36.498 filas** en su aritmética y reproduzco **24.269 evaluaciones** sin diferencias.
 Recalculo **5.668.694 filas por cliente** y concilio sus agregados nacionales. La selección y el
 orden de las alertas coinciden exactamente con el CSV guardado.

```
In [65]: display(Markdown(tabla_markdown(
    ['Escenario', 'Alertas', 'Sin base', 'Retenidas', 'Nuevas', 'Retiradas', 'Jacca
    [[s['escenario'], formato(s['alertas']), formato(s['sin_base']),
    formato(s['retenidas']), formato(s['nuevas']), formato(s['retiradas']),
    formato(s['jaccard'], 4)] for s in revision['sensibilidad']]),
    )))
```

Escenario	Alertas	Sin base	Retenidas	Nuevas	Retiradas	Jaccard
Configuración actual	6.393	0	6.393	0	0	1,0000
Puntuación mínima = 2	6.671	0	6.393	278	0	0,9583
Puntuación mínima = 4	6.119	0	6.119	0	274	0,9571
Puntuación mínima = 6	5.677	0	5.677	0	716	0,8880
Clientes mínimos = 25	6.031	0	6.031	0	362	0,9434
Clientes mínimos = 100	4.921	0	4.921	0	1.472	0,7697
Exceso mínimo = 25	6.012	0	6.012	0	381	0,9404
Exceso mínimo = 100	4.859	0	4.859	0	1.534	0,7601
Mínimo de 3 referencias	0	24.269	0	0	6.393	0,0000
Escenario: 6 referencias, k=3	0	24.269	0	0	6.393	0,0000

```
In [66]: display(Markdown(
    '### 10.5. Qué aprendo de la sensibilidad\n\n'
    f'Reproduzco **{formato(revision['sensibilidad'][0]['alertas'])} alertas** con
    'Las tablas muestran cuántas retengo, incorporo y retiro al cambiar puntuación,
    'Con tres referencias mínimas o con seis y k=3, las dos referencias disponibles
    'No interpreto cero alertas de esos escenarios como mejoría o ausencia de probl
    'Calculo Jaccard como intersección/unión de las llaves partido-nivel-zona respe
    'Mido estabilidad de la selección, no precisión contra casos confirmados. Al qu
    'La calibración requiere más referencias comparables, evidencia independiente y
    ))
```

10.5. Qué aprendo de la sensibilidad

Reproduzco **6.393 alertas** con la configuración vigente. Las tablas muestran cuántas retengo, incorporo y retiro al cambiar puntuación, clientes mínimos o exceso mínimo. Con tres referencias mínimas o con seis y $k=3$, las dos referencias disponibles no permiten evaluar y obtengo SIN_BASE. No interpreto cero alertas de esos escenarios como mejoría o ausencia de problemas.

Calculo Jaccard como intersección/unión de las llaves partido–nivel–zona respecto de la configuración vigente. Mido estabilidad de la selección, no precisión contra casos confirmados. Al quitar horarios repetidos persisten ventanas solapadas y territorios anidados. La calibración requiere más referencias comparables, evidencia independiente y criterios de relevancia.

11. Resultados y métricas interpretados

11.1. Resultado nacional y unidades de comparación

Utilizo la fila nacional del **periodo completo**, contada por separado, y el promedio aritmético de 2024 y 2025. No sumo clientes distintos por día, territorio ni ventanas de partidos. Separo incidencias generales de pares cliente–incidencia: una incidencia que afecta a cien clientes puede aportar cien pares.

```
In [67]: nacional = datos['nacional']
metricas = {
    'CLIENTES_DISTINTOS': 'Clientes afectados distintos',
    'INCIDENCIAS_DISTINTAS': 'Incidencias distintas asociadas a clientes',
    'MAC_DISTINTAS': 'Dispositivos MAC distintos',
    'FALLAS_CLIENTE': 'Pares distintos cliente-incidencia',
}
display(Markdown(tabla_markdown(
    ['Métrica', '2024', '2025', '2026', 'Promedio histórico', 'Diferencia', 'Variac
    [[nombre, formato(nacional[m+'_2024']), formato(nacional[m+'_2025']),
      formato(nacional[m]), formato(nacional['PROMEDIO_HISTORICO_'+m]),
      formato(nacional['DIF_'+m+'_VS_HISTORICO']),
      formato(nacional['VAR_'+m+'_PCT_VS_HISTORICO'], 2)+' %']
    for m, nombre in metricas.items()]),
)))
repeticion_actual = int(nacional['FALLAS_CLIENTE']) / int(nacional['CLIENTES_DISTIN
repeticion_base = (float(nacional['PROMEDIO_HISTORICO_FALLAS_CLIENTE']) /
                    float(nacional['PROMEDIO_HISTORICO_CLIENTES_DISTINTOS']))
display(Markdown(
    f"Calculo **{formato(repeticion_actual, 4)} pares por cliente afectado en 2026*
    f"frente a **{formato(repeticion_base, 4)}** en la referencia agregada "
    f"(*+{formato(100*(repeticion_actual/repeticion_base-1), 2)} %**). "
    'Divido promedios de conteos; no promedio las dos razones anuales.'
))
```

Métrica	2024	2025	2026	Promedio histórico	Diferencia	Variación
Clientes afectados distintos	3.160.907	2.850.489	3.346.873	3.005.698	341.175	11,35 %
Incidencias distintas asociadas a clientes	124.795	114.157	182.116	119.476	62.640	52,43 %
Dispositivos MAC distintos	3.770.229	3.260.411	3.718.749	3.515.320	203.429	5,79 %
Pares distintos cliente-incidencia	6.933.682	6.179.984	8.711.270	6.556.833	2.154.437	32,86 %

Calculo **2,6028 pares por cliente afectado en 2026**, frente a **2,1815** en la referencia agregada (+**19,31** %). Divido promedios de conteos; no promedio las dos razones anuales.

```
In [68]: display(Markdown(
    f"Encuentro **{formato(nacional['DIF_FALLAS_CLIENTE_VS_HISTORICO'])} pares de d
    f"Sus variaciones frente a cada año son **{formato(nacional['VAR_FALLAS_CLIENTE
    f"**{formato(nacional['VAR_FALLAS_CLIENTE_PCT_VS_2025'], 2)} %**."
    f"Las MAC varían **{formato(nacional['VAR_MAC_DISTINTAS_PCT_VS_HISTORICO'], 2)}
    f"y **{formato(nacional['VAR_MAC_DISTINTAS_PCT_VS_2024'], 2)} %** frente a 2024
    'No generalizo que todas las métricas cambien en el mismo sentido frente a cada
    '### 11.2. Concentración territorial y temporal\n\n'
    f"Encuentro aumento de pares en **{indicadores['entidades_aumento']} entidades*
    f"**{indicadores['dias_aumento_pares']} días**. Las dos entidades con mayor con
    f"**{formato(indicadores['participacion_dos_entidades'], 2)} % del cambio neto
    f"El 18 y 19 de junio aportan **{formato(indicadores['pares_adicionales_picos']
    f"**{formato(indicadores['porcentaje_incremento_picos'], 2)} %** del cambio net
    'Uso esa concentración para ubicar candidatos de revisión, no para atribuir cau
    'El denominador es el cambio neto, que incluye descensos en otros territorios;
    ))
```

Encuentro **2.154.437 pares de diferencia** frente al histórico. Sus variaciones frente a cada año son **25,64 %** y **40,96 %**. Las MAC varían **5,79 %** frente al promedio, y **-1,37 %** frente a 2024. No generalizo que todas las métricas cambien en el mismo sentido frente a cada año.

11.2. Concentración territorial y temporal

Encuentro aumento de pares en **28 entidades** y **32 días**. Las dos entidades con mayor contribución concentran **59,37 % del cambio neto nacional**. El 18 y 19 de junio aportan **611.697 pares de diferencia**, **28,39 %** del cambio neto del periodo. Uso esa concentración para ubicar candidatos de revisión, no para atribuir causas deportivas. El denominador es el cambio neto, que incluye descensos en otros territorios; no es el total de fallas.

```
In [69]: display(Markdown(tabla_markdown(
    ['Entidad del catálogo', 'Pares 2026', 'Diferencia frente al histórico', 'Varia
    [[f['ZONA'], formato(f['FALLAS_CLIENTE']),
    formato(f['DIF_FALLAS_CLIENTE_VS_HISTORICO'], 1),
    formato(f['VAR_FALLAS_CLIENTE_PCT_VS_HISTORICO'], 2)+' %']
    for f in indicadores['top_entidades']]),
```

```

)))
display(Markdown(
    f"Recalculo **{formato(indicadores['participacion_dos_entidades'], 2)} %** "
    'del aumento neto en las dos primeras entidades y '
    f"**{formato(indicadores['porcentaje_incremento_picos'], 2)} %** "
    'en los días 18 y 19 de junio.'
))

```

Entidad del catálogo	Pares 2026	Diferencia frente al histórico	Variación
NUEVO LEON	1.771.424	777.787,5	78,28 %
CIUDAD DE MEXICO	1.663.504	501.201,5	43,12 %
MEXICO	905.101	182.531,0	25,26 %
TAMAULIPAS	611.750	142.401,0	30,34 %
SAN LUIS POTOSI	147.179	68.184,5	86,32 %

Recalculo **59,37 %** del aumento neto en las dos primeras entidades y **28,39 %** en los días 18 y 19 de junio.

11.3. Alertas y utilidad todavía no demostrada

Reproduzco los estados con el código vigente y cuantifico su selección en la tabla siguiente. Interpreto **ANOMALIA** como cumplimiento de reglas y **ESPERADO** como incumplimiento de al menos una; ninguno acredita por sí solo normalidad o causalidad. La proporción de alertas describe filas evaluadas, no fallas verdaderas ni clientes activos.

```

In [70]: display(Markdown(tabla_markdown(
    ['Nivel', 'Evaluaciones', 'Alertas'],
    [[p['nivel'], formato(p['evaluaciones']), formato(p['alertas'])]
     for p in indicadores['por_nivel']],
    )))
display(Markdown(tabla_markdown(
    ['Indicador de selección', 'Valor', 'Denominador o alcance'],
    [
        ['Alertas / evaluaciones', formato(indicadores['porcentaje_alertas'], 2)+'
         f"{formato(indicadores['alertas'])} / {formato(indicadores['evaluaciones'])}
         ['Alertas con ambos históricos de clientes en cero', formato(indicadores['a
         formato(indicadores['porcentaje_alertas_cero'], 2)+' % de las alertas'],
         ['Alertas con promedio histórico de clientes < 10', formato(indicadores['al
         formato(indicadores['porcentaje_alertas_menos10'], 2)+' % de las alertas;
         ['Evaluaciones sin repetir horario-nivel-zona', formato(indicadores['evalua
         'Siguen existiendo solapamientos'],
         ['Alertas sin repetir horario-nivel-zona', formato(indicadores['alertas_hor
         'Siguen existiendo territorios anidados'],
    ],
    )))

```

Nivel	Evaluaciones	Alertas
NACIONAL	104	38
ENTIDAD_FEDERATIVA	2.947	677
HUB_CM	8.065	2.078
PLAZA	13.153	3.600

Indicador de selección	Valor	Denominador o alcance
Alertas / evaluaciones	26,34 %	6.393 / 24.269 filas partido–nivel–zona
Alertas con ambos históricos de clientes en cero	2.459	38,46 % de las alertas
Alertas con promedio histórico de clientes < 10	3.195	49,98 % de las alertas; incluye las de cero
Evaluaciones sin repetir horario–nivel–zona	21.514	Siguen existiendo solapamientos
Alertas sin repetir horario–nivel–zona	5.700	Siguen existiendo territorios anidados

```
In [71]: display(Markdown(
    f"Identifico **{formato(indicadores['alertas'])} alertas** y **{formato(indicad
    f"Sin repetir horario–nivel–zona quedan **{formato(indicadores['alertas_horario
    f"en **{formato(indicadores['evaluaciones_horario_distinto'])} evaluaciones**."
    f"Los **{datos['resumen']['partidos']} partidos** tienen **{indicadores['horari
    f"De las alertas, **{formato(indicadores['alertas_cero'])}** tienen ambos histó
    f"(**{formato(indicadores['porcentaje_alertas_cero'], 2)} %**). "
    f"***{formato(indicadores['alertas_menos10'])}** tienen promedio histórico infer
    f"(**{formato(indicadores['porcentaje_alertas_menos10'], 2)} %**); este grupo i
    'No sumo categorías anidadas. Verificaría cobertura y equivalencias territorial
    'Leo alertas_ordenadas.csv como una lista ordenada por exceso de clientes. Prop
    '### 11.4. Recurrencia reproducible desde las salidas\n\n'
    'Recalculo el histograma y la cohorte desde fallas_generales_por_cliente.csv me
    'Compruebo identificadores únicos y ordenados y concilio clientes y pares con e
    'Mi cálculo utiliza las salidas actuales, sin informes precalculados de otros d
    ))
```

Identifico **6.393 alertas** y **17.876 ESPERADO**. Sin repetir horario–nivel–zona quedan **5.700 alertas** en **21.514 evaluaciones**. Los **104 partidos** tienen **92 inicios distintos**.

De las alertas, **2.459** tienen ambos históricos de clientes en cero (**38,46 %**). **3.195** tienen promedio histórico inferior a diez (**49,98 %**); este grupo incluye el anterior. No sumo categorías anidadas. Verificaría cobertura y equivalencias territoriales antes de considerar extraordinaria una referencia cero.

Leo alertas_ordenadas.csv como una lista ordenada por exceso de clientes. Propongo candidatos de investigación sin asignarles probabilidad, significancia o criticidad empresarial.

11.4. Recurrencia reproducible desde las salidas

Recalculo el histograma y la cohorte desde fallas_generales_por_cliente.csv mediante lectura en flujo. Compruebo identificadores únicos y ordenados y concilio clientes y pares con el nacional de cada año. Mi cálculo utiliza las salidas actuales, sin informes precalculados de otros documentos.

```
In [72]: display(Markdown(tabla_markdown(
    ['Fallas registradas en 2026', 'Clientes', '% de afectados en 2026'],
    [[p['categoria'], formato(p['clientes']),
      formato(100*p['clientes']/int(nacional['CLIENTES_DISTINTOS'])) if int(nacional
        for p in indicadores['recurrencia']],
    )))
cohorte = indicadores['clientes']['cohorte_con_fallas_en_los_tres_anios']
referencia_cohorte = (cohorte['2024'] + cohorte['2025']) / 2
display(Markdown(
    f"Recalculo **{formato(cohorte['clientes'])} identificadores con fallas en los
    f"sus pares varían **{formato(100*(cohorte['2026']/referencia_cohorte-1)} if ref
    'La seleccón por afectación en los tres años no representa a toda la cartera.'
    ))
```

Fallas registradas en 2026	Clientes	% de afectados en 2026
Exactamente una	1.317.576	39,37 %
Dos o más	2.029.297	60,63 %
Cinco o más	465.976	13,92 %
Diez o más	48.440	1,45 %

Recalculo **976.185 identificadores con fallas en los tres años**: sus pares varían **24,89 %**. La seleccón por afectación en los tres años no representa a toda la cartera.

```
In [73]: dos_o_mas = next(p['clientes'] for p in indicadores['recurrencia'] if p['categoria']
porcentaje_recurrencia = 100 * dos_o_mas / int(nacional['CLIENTES_DISTINTOS']) if i
display(Markdown(
    f"Encuentro **{formato(porcentaje_recurrencia, 2)} ** de afectados con dos o m
    'Las categorías de dos, cinco y diez o más son anidadas. La cohorte con fallas
    'mantiene identificadores comunes, pero selecciona precisamente clientes recurr
    'no deduzco continuidad del servicio ni representatividad de toda la cartera.\n
```

```

'### 11.5. Contraste entre descripción y clasificación\n\n'
'Comparo el resultado descriptivo con el comportamiento del detector bajo disti
'Mantengo los conteos y cambio las reglas de evaluación; así identifico qué dep
'sin presentar una simulación como una ejecución histórica reconstruida.'
))

```

Encuentro **60,63 %** de afectados con dos o más incidencias. Las categorías de dos, cinco y diez o más son anidadas. La cohorte con fallas en los tres años mantiene identificadores comunes, pero selecciona precisamente clientes recurrentemente afectados: no deduzco continuidad del servicio ni representatividad de toda la cartera.

11.5. Contraste entre descripción y clasificación

Comparo el resultado descriptivo con el comportamiento del detector bajo distintos requisitos de referencia. Mantengo los conteos y cambio las reglas de evaluación; así identifico qué depende de las reglas sin presentar una simulación como una ejecución histórica reconstruida.

```

In [74]: actual = revision['sensibilidad'][0]
sin_base = next(s for s in revision['sensibilidad'] if s['minimo_referencias'] == 6)
display(Markdown(tabla_markdown(
    ['Aspecto', 'Configuración vigente', 'Escenario de seis referencias y k=3', 'Mi
    [
        ['Mínimo de referencias / k', f"{actual['minimo_referencias']} / {actual['k
        ['Alertas', formato(actual['alertas']), formato(sin_base['alertas']), 'La d
        ['Sin base', formato(actual['sin_base']), formato(sin_base['sin_base']), 'L
        ['Comparación nacional', 'Conteos actuales', 'Los mismos conteos', 'La desc
        ['Causalidad', 'No identificada', 'No identificada', 'El cambio de clasific
        ['Validación', 'Recalculo agregados, detector y recurrencia', 'Simulo el re
    ]
)))

```

Aspecto	Configuración vigente	Escenario de seis referencias y k=3	Mi interpretación
Mínimo de referencias / k	2 / 1	6 / 3	Cambio requisitos, no los datos.
Alertas	6.393	0	La diferencia resulta de las reglas del detector.
Sin base	0	24.269	La falta de referencias no demuestra normalidad.
Comparación nacional	Conteos actuales	Los mismos conteos	La descripción no depende de emitir alertas.
Causalidad	No identificada	No identificada	El cambio de clasificación no aporta identificación causal.
Validación	Recalculo agregados, detector y recurrencia	Simulo el requisito sobre los mismos vectores	No sustituyo una revisión externa de eventos.

El resultado descriptivo y la clasificación responden a preguntas diferentes. Mis conteos permiten comparar el extracto registrado; la regla KNN selecciona candidatos según sus referencias. Elevar el mínimo a seis impide evaluar con dos controles y no elimina las afectaciones observadas.

Reproduzco ese efecto sobre los mismos vectores y conservo explícitos los parámetros de cada escenario. No necesito informes de otras versiones para efectuar el contraste. La ejecución técnicamente posible con dos referencias no demuestra que la fiabilidad operativa haya mejorado.

12. Conclusiones y decisión

12.1. Cómo respondo mi pregunta inicial

Mi pregunta es si durante el Mundial 2026 hubo más fallas registradas en izzi y si ese aumento puede atribuirse al torneo o extenderse a ViX. Para la evaluación académica separo tres afirmaciones:

Afirmación que evalúo	Evidencia y criterio	Decisión académica que tomo
Aumentaron las afectaciones registradas de izzi en el periodo.	Comparo conteos del periodo completo; pares e incidencias aumentan frente a 2024, 2025 y su promedio.	La respaldo descriptivamente para el extracto elegible y enlazado. No la convierto en tasa sobre toda la red.
El Mundial causó el aumento.	Necesitaría distinguir exposición y otras causas con un diseño causal y datos adicionales. La coincidencia de fechas y las alertas KNN no cumplen ese criterio.	No respaldo la atribución causal con la evidencia disponible. No reporto un rechazo estadístico de la hipótesis: no ejecuté una prueba causal válida.
ViX tuvo más fallas por el Mundial.	Necesitaría registros específicos de ViX, usuarios o sesiones expuestas y métricas de reproducción o servicio. Los extractos no identifican esas variables.	Declaro la afirmación no evaluable en mi conjunto; no traslado las fallas generales de izzi a ViX.

Utilizo el resultado para mi evaluación académica y lo presento con estos límites. Mi decisión es conservar el hallazgo descriptivo y no afirmar causalidad del Mundial ni ausencia de relación. La alternativa «fue debido al Mundial o no tienen relación» no puede resolverse como un sí/no con estos datos.

12.2. Qué acción recomiendo y con qué criterio

Para el cierre académico recomiendo informar el aumento y la incertidumbre causal, y dejar explícita la insuficiencia del detector para confirmar causas. Si continuara la investigación, priorizaría **Nuevo León el 18 y 19 de junio** y después Ciudad de México por su

contribución absoluta al aumento, agrupando por incidencia para evitar repetir eventos entre partidos y niveles. Es una recomendación de revisión; no afirmo que un área de izzi la haya autorizado o ejecutado.

Antes de interpretar candidatos con referencia cero comprobaría cobertura y vigencias territoriales. Para una atribución al Mundial solicitaría tráfico, audiencia o exposición, cartera activa, duración y causas de incidentes, además de periodos previos y posteriores y controles comparables. Evaluaría tendencias, estacionalidad y otras causas antes de elegir un diseño causal. No sustituyo aquí las mismas fechas de 2024 y 2025 por periodos de control nuevos.

Si quisiera evaluar ViX, necesitaría su propia telemetría de reproducción, errores, sesiones y disponibilidad. La vinculación comercial con izzi no convierte los registros de Internet, Telefonía y Vídeo en mediciones directas de ViX.

13. Beneficios y aportaciones

13.1. Qué aporta mi trabajo y cómo lo comprobaría

Distingo las aportaciones que puedo demostrar con mis artefactos de los beneficios operativos que sólo puedo proponer. No tengo evidencia de ahorro, tiempos reducidos de atención ni menos fallas atribuibles a este análisis.

Aportación que identifiqué	Evidencia disponible	Indicador que utilizo o propongo
Comparo unidades sin confundir clientes, incidencias y pares.	Concilio las filas agregadas y sus diferencias y porcentajes; presento sus contadores en 10.4.	Utilizo diferencias aritméticas detectadas: cero en esta revisión, dentro del alcance de los controles.
Puedo reproducir la selección y revisar versiones.	Reproduzco las evaluaciones y el orden de las alertas y registro las fuentes actuales con huellas.	Utilizo discrepancias con el evaluador: cero; registro rutas, tamaños y SHA-256, sin equiparlos a exhaustividad de la fuente.
Ubico concentración temporal y territorial.	Cuantifico la contribución de entidades y días al cambio neto en 11.2.	Propongo medir eventos confirmados revisados por territorio y fecha; no utilizo concentración como precisión.
Hago visible la recurrencia entre afectados.	Recalculo el histograma y la cohorte con los resultados presentados en 11.4.	Propongo medir recurrencia con identificación estable y cartera activa; para mejoría necesitaría seguimiento comparable.
Muestro dependencia de los umbrales.	Exporto diez escenarios, alertas retenidas, retiradas y nuevas y Jaccard.	Utilizo estabilidad de la selección; propongo añadir precisión y sensibilidad cuando disponga de etiquetas independientes.

Aportación que identifiqué	Evidencia disponible	Indicador que utilizo o propongo
Evito una conclusión causal que no está acreditada.	Separo aumento observado, causa no identificada y ViX no medido.	Utilizo una trazabilidad entre cada afirmación, su fuente y su límite; no invento una puntuación empresarial para esta aportación.

13.2. Beneficios potenciales que todavía no acredito

Una investigación posterior podría aprovechar la lista de candidatos para dirigir revisiones y rastrear afectaciones. Para comprobarlo propondría registrar la fracción de candidatos revisados, eventos confirmados por revisión, incidencias únicas revisadas sin duplicar ventanas, tiempo hasta confirmación y carga de revisión. Definiría periodos de medición y un criterio de confirmación antes de calcularlos. Hoy esos indicadores no están disponibles; no asigno metas ni ahorros supuestos.

Si se buscara medir reducción de fallas, necesitaría una línea base, seguimiento, intervención identificada y control de cambios en población y captura. Una menor cifra posterior, por sí sola, no demostraría un beneficio causado por mi análisis. Mi aportación acreditada en este proyecto es **analítica, documental y reproducible**.

14. Limitaciones y supuestos

14.1. Qué compruebo y qué condición sigue abierta

Aspecto	Evidencia o supuesto que delimito	Consecuencia para mi interpretación
Reglas de selección y extracción	Retomo la estabilidad de reglas de 2024–2026 confirmada y documentada en la sección 4. No he auditado todas las cargas dbt ni sus fechas y parámetros.	No equiparo la confirmación declarada a prueba técnica de cobertura uniforme. Los manifiestos de exportación completos siguen pendientes.
Completitud del extracto	Compruebo presencia diaria y cruces según el control, no todas las fallas que realmente ocurrieron.	<code>COBERTURA_COMPLETA=True</code> no acredita exhaustividad por territorio, hora o servicio.
Fechas excluidas y corte	Conservo el periodo de extracción aproximado y los pendientes de fechas ilegibles/vacías de las secciones 5 y 6.	No supongo que cada exclusión previa fuera una fecha válida fuera del rango. No he reabierto las fuentes originales.

Aspecto	Evidencia o supuesto que delimito	Consecuencia para mi interpretación
Cambios territoriales	Necesitaría equivalencia de códigos, etiquetas, vigencias y asociaciones de clientes entre años. No dispongo de una auditoría completa de cambios de catálogo.	No interpreto automáticamente un histórico cero como ausencia real de fallas; podría reflejar cambios de cobertura o clasificación.
Población, tecnología y servicio	No tengo cartera activa ni exposición homogénea acreditada por tecnología y servicio en los tres años.	No estimo probabilidad por abonado, disponibilidad ni tasas comparables de toda la red.
Mecanismo de registro	La equivalencia de detección, asociación y fragmentación de tickets necesitaría respaldo operacional.	El aumento de incidencias puede incluir cambios de captura; no declaro que esto haya ocurrido ni que explique el aumento.
Comparabilidad temporal	Alineo mes, día y hora local, sin igualar día semanal, festivos, demanda ni contexto operacional.	Las referencias no aíslan el efecto del torneo frente a estacionalidad, tendencia o causas concurrentes.
Referencias del detector	Sólo tengo dos controles por ventana; $k=1$ permite calcular pero no calibrar normalidad.	Los percentiles y puntuaciones no acreditan significancia, probabilidad ni fiabilidad operativa.
Dependencia de observaciones	Las ventanas se solapan y los niveles se anidan; quitar horarios repetidos no elimina esa dependencia.	No trato las filas como ensayos independientes ni sumo clientes o alertas para contar eventos únicos.
Verdad externa	No tengo casos confirmados ni revisión independiente de positivos y negativos.	No reporto precisión, sensibilidad ni utilidad operativa validada.
Causalidad del Mundial	No mido exposición y no dispongo de un contrafactual identificado ni de causas verificadas.	La comparación y KNN no permiten atribuir el aumento al torneo ni probar ausencia de relación.
ViX	No tengo telemetría ni fallas específicas de su plataforma.	Limito mis conclusiones a registros de izzi; ViX queda fuera de la medición directa.
Trazabilidad técnica y organizacional	Registro huellas de archivos actuales; no dispongo de manifiestos completos de exportación y corte del Warehouse.	Reproduzco el análisis local sin presentar sus huellas como autenticación del origen empresarial.

No doy por cumplidas las condiciones abiertas: las explico para que mi conclusión no dependa de una suposición silenciosa. Mis huellas identifican los archivos utilizados en esta revisión; no prueban su origen empresarial ni rellenan los pendientes documentales de extracción.

14.2. Fechas, ceros y fronteras de evidencia

Mi periodo operativo, definido en `config.json`, comprende **11 de junio–19 de julio de 2026**, ambos incluidos; el final técnico exclusivo es el 20 de julio a las 00:00. El filtro previo conserva 10 de junio–20 de julio para los márgenes de las ventanas. No uso ese margen como control ni confundo fechas sintéticas de pruebas con fechas del análisis. Conservo la conversión de `FECHA_INCIDENCIA` desde UTC y la interpretación local de `FECHA_ENVIO` documentadas en la sección 6.

Un porcentaje vacío con referencia cero no vale cero por ciento. Un cero con presencia global de datos indica ausencia de afectaciones enlazadas en esa referencia según el programa; no confirma por sí mismo cobertura territorial estable. `SIN_BASE` indica imposibilidad de evaluar por referencias insuficientes; no indica normalidad. `ESPERADO` tampoco acredita ausencia de fallas.

En mis celdas recalculo comparaciones agregadas, campos del evaluador, selección y orden de alertas y sensibilidad. Recalculo los agregados del CSV por cliente con lectura en flujo y los concilio con el nacional. No repito la auditoría completa del detalle de alertas ni la extracción original. Mi conclusión conserva exactamente esa frontera de evidencia.

15. Conclusión válida aunque el modelo sea insuficiente

15.1. Balance entre lo descriptivo y el detector

Mi comparación descriptiva permite cuantificar el volumen, la repetición y la distribución de afectaciones elegibles registradas. Esos resultados proceden de conteos del periodo completo y de intervalos comparables, sin depender de que KNN emita alertas.

Mi detector genera candidatos técnicamente reproducibles. La escasez de referencias, los históricos cero, la dependencia entre ventanas y la ausencia de casos confirmados impiden interpretarlos como eventos extraordinarios validados o causas del Mundial. La sensibilidad describe dependencia de las reglas y no acredita fiabilidad operativa.

15.2. Mi conclusión final sobre izzi, ViX y el Mundial

Respondo la pregunta a partir de los conteos vigentes que recalculo en el cierre siguiente. Para la ejecución utilizada observo un aumento descriptivo de clientes, incidencias y pares frente al promedio histórico. Limito esa respuesta al extracto elegible registrado y enlazado; no la presento como una tasa sobre toda la cartera.

No identifico si el Mundial causó las diferencias ni demuestro ausencia de relación.

Tampoco evalúo fallas específicas de ViX porque mis fuentes no contienen su telemetría o

exposición. Mi decisión académica es conservar el hallazgo descriptivo de izzi y declarar la atribución causal no demostrada y ViX fuera de la medición directa.

Mi reproducción utiliza [configuración](#), [análisis](#), [control](#), [resumen](#), [periodo](#), [días](#), [partidos](#), [alertas](#), [clientes](#), [EDA](#), [revisión](#), [validación](#) y [dependencias](#).

Conservo la [sensibilidad](#), el [resumen recalculado](#), las [huellas de fuentes](#) y la [validación de esta copia](#) en una carpeta propia. El contenido de otro notebook no interviene en mis cálculos ni en estos auxiliares.

16. Bonus

Hola Profesor.

La realidad es que escogí este proyecto ya que yo fui la persona que desarrollo la entidad de **mt_incidencias_clientes** (no la entidad de fallas_generales) hace un par de meses y se me hizo algo peculiar como es que en 2026 una empresa de las más grandes de Telco, no tenía idea de cuántos clientes tuvieron alguna afectación a lo largo del día.

Inicialmente eso me pareció un buen punto de partida pero el volumen de los datos era inmenso, eso me hizo descartar el tomar información de las dimensiones de clientes o equipos. A pesar de sólo enfocarme a un periodo de 39 días, ¡terminé trabajando con un volumen de más de 25 millones de datos limpios! lo cual fue todo un reto. Ya que, al haber renunciado de izzi, ya no contaba con el poder bruto de Snowflake ni su eficiente manejo de los datos, por eso tampoco pude hacer muchas pruebas para valores diferentes en k . La parte del fine-tuning es un área de oportunidad que pude identificar en este proyecto. De igual manera, estoy feliz de haber podido "jugar" con esa información del Warehouse, que por obvias razones, eliminaré de mi cuenta de Google Drive en cuanto reciba una calificación de este módulo. Gracias por todo.

- Efrén Vega Barrera